Mô tả dữ liệu từ điển Hán Nôm và Quốc ngữ
Cấu trúc dữ liệu và nguồn gốc

Thông tin phiên bản

Phiên bản	Ngày cập nhật	Thông tin
v1	03/11/2026	Phiên bản đầu tiên. Dữ liệu gồm 12 nguồn, khoảng 969.000 mục từ, cấu trúc dữ liệu (schema) v1.

Tổng quan

- Tài liệu mô tả cách tổ chức bộ dữ liệu từ điển Hán, Nôm và Quốc ngữ: các file dữ liệu, cấu trúc của mỗi bản ghi, ý nghĩa từng trường và nguồn gốc dữ liệu.
- Các từ điển gốc có định dạng rất khác nhau, nên đã được đưa về chung **một dạng bản ghi** gọi là **Entry**. Mỗi nguồn được lưu thành một file JSONL.
- Dữ liệu gồm chữ và từ Hán/Nôm, âm đọc (Quốc ngữ, Hán Việt, Nôm, pinyin), nghĩa tiếng Việt và tiếng Anh, dị thể, cấu tạo chữ.

Quy mô

- Bộ dữ liệu gồm **12** nguồn: 11 nguồn đã đo, tổng cộng **716.727 mục từ** (xem **Độ phủ**), và một tập con của `catusf` gồm 5 từ điển, **252.732 mục từ** theo số khai báo (xem **Các từ điển lấy từ catusf**).
- Đây là số bản ghi, không phải số từ khác nhau: các nguồn có thể trùng nhau và chưa được thống kê phần trùng (xem **Hạn chế đã biết**).

Cấu trúc thư mục dữ liệu

```
entries/
|-- btcn.jsonl
|-- catusf.jsonl
|-- cc_cedict.jsonl
|-- cjkvi_ids.jsonl
|-- cjkvi_variants.jsonl
|-- dnqatv_wikisource.jsonl
|-- dv.jsonl
|-- hannom_rcv.jsonl
|-- hvdic.jsonl
|-- makemeahanzi.jsonl
|-- moedict.jsonl
`-- unihan.jsonl
```

- Mỗi file có dạng `<source>.jsonl`, mã hóa UTF-8, **mỗi dòng là một Entry** (một đối tượng JSON).
- Tên file chính là mã nguồn, cũng là giá trị của trường `source` trong từng bản ghi.
- `catusf.jsonl` là file đã lọc, chỉ giữ 5 từ điển trong bộ `catusf` (xem **Các từ điển lấy từ catusf**).

Nguyên tắc xây dựng dữ liệu

- **Không suy đoán.** Âm đọc chỉ được gán là `hv` hoặc `nom` khi nguồn ghi rõ; các trường hợp còn lại để là `qn`.
- **Giữ nguyên dữ liệu gốc.** Không gộp dị thể, không quy đổi giản thể/phồn thể, không đổi dấu thanh. Chỉ chuẩn hóa NFC và đưa âm Quốc ngữ về chữ thường.
- **Chỉ loại trùng trong cùng một nguồn.** Một từ xuất hiện ở nhiều nguồn thì mỗi nguồn giữ một bản ghi riêng.
- **Truy được về nguồn.** Mỗi mục từ có trường `ref` ghi lại trang hoặc file mà mục từ được lấy ra.

Bản ghi mục từ (Entry)

Mỗi dòng trong `entries/<source>.jsonl` là một Entry. Mọi nguồn đều dùng chung dạng bản ghi này.

Các trường

Trường	Kiểu	Ý nghĩa
`id`	chuỗi	Mã định danh, có dạng `<source>:<ext_id>`; không trùng nhau trong toàn bộ dữ liệu.
`source`	chuỗi	Mã nguồn, trùng với tên file.
`kind`	`char` hoặc `word`	Loại mục từ: một chữ (`char`) hoặc một từ (`word`).
`head`	chuỗi (NFC)	Chữ hoặc từ Hán/Nôm của mục từ. Với từ điển Quốc ngữ (như Đại Nam Quấc âm tự vị) thì là từ Quốc ngữ.
`script`	enum	Loại chữ viết của `head`: `han`, `nom`, `qn`, `kana`, `hangul`, `latin`, `other` (dấu câu, ký hiệu, chữ số, bảng chữ cái khác).
`parent`	chuỗi, tùy chọn	`id` của mục cha, dùng cho mục con.
`forms`	danh sách `{text, script}`	Các cách viết khác của `head`. Với từ Quốc ngữ, đây là nơi ghi các cách viết bằng chữ Nôm.
`readings`	danh sách `{value, system}`	Âm đọc. `system` nhận một trong: `qn`, `hv`, `nom`, `pinyin`, `jyutping`, `on`, `kun`, `hangul`, `other`.
`senses`	danh sách `{text, lang, pos?}`	Nghĩa của mục từ. `lang` là ngôn ngữ của phần giải nghĩa.
`cites`	danh sách `{text, work?, kind}`	Câu trích hoặc ví dụ. `kind`: `cite` (trích dẫn) hoặc `example` (ví dụ).
`variants`	danh sách `{char, type}`	Chữ dị thể. `type`: `trad`, `simp`, `z`, `semantic`, `spec`, `other`.
`glyphs`	danh sách `{style, ref}`	Các dạng chữ trong lịch sử; `ref` trỏ tới hình ảnh ở kho dữ liệu gốc (không đi kèm bộ dữ liệu này).
`parts`	đối tượng	Thông tin cấu tạo chữ: `ids?`, `radical?`, `strokes?`, `formation?`, `components?` (danh sách các chữ thành phần).
`freq`	số nguyên 0..1000, tùy chọn	Mức độ thông dụng; càng cao càng thông dụng.

Trường	Kiểu	Ý nghĩa
`relations`	danh sách `{type, to}`	Quan hệ với mục từ khác; `to` là chuỗi `head` của mục đó.
`unencoded`	boolean	`true` nếu chữ chưa có mã Unicode; khi đó `head` là chuỗi IDS hoặc `@img:<ref>`.
`extra`	đối tượng	Dữ liệu riêng của từng nguồn, giữ nguyên như bản gốc. Với `catusf`, `extra.dict` là mã của từ điển chứa mục từ.
`ref`	đối tượng	Nơi mục từ được lấy ra: `url?`, `url_alt?`, `raw_path?`. `url_alt` ghi các trang còn lại của một mục `dv` đã được gộp.

Quy tắc kiểm tra

- Các trường dạng liệt kê (enum) chỉ nhận những giá trị đã nêu ở trên.
- Mục `char` thuộc `han` hoặc `nom` chỉ có đúng một code point (không tính variation selector), trừ khi `unencoded` là `true`.
- `freq` là số nguyên từ 0 đến 1000.
- `id` không trùng nhau trong cùng một nguồn.

Chuẩn hóa

- Mọi chuỗi đều ở dạng NFC.
- Âm đọc `qn`, `hv`, `nom` được đưa về chữ thường.
- Ngoài hai điểm trên, nội dung bản ghi được giữ nguyên.

Nguồn gốc của âm đọc

Âm đọc chỉ được gán là `hv` (Hán Việt) hoặc `nom` (Nôm) khi nguồn ghi rõ, hoặc khi toàn bộ nguồn đó thuộc một loại. Các trường hợp còn lại gán là `qn`, không suy đoán.

Ví dụ

Ví dụ dưới đây chỉ để minh họa và đã được rút gọn; mã định danh và giá trị thực tế khác nhau tùy từng nguồn.

```
{"id":"unihan:U+4EBA","source":"unihan","kind":"char","head":"人","script":"han",
 "readings":[{"value":"rén","system":"pinyin"},{"value":"nhân","system":"hv"}],
 "senses":[{"text":"man; people","lang":"en"}],
 "parts":{"strokes":2}}
```

Đọc dữ liệu

```
import json
with open("entries/unihan.jsonl", encoding="utf-8") as f:
    for line in f:
        entry = json.loads(line)
```

Nguồn dữ liệu

Độ phủ

Mục từ là số bản ghi; *Head khác nhau* là số chữ/từ không trùng nhau (tính theo cặp chữ viết và `head`).

Nguồn	Mục từ	Head khác nhau	Số chữ / số từ	Chữ viết và ngôn ngữ của phần nghĩa
`btcn`	8.107	8.107	8.107 / 0	nom 8.107; không có phần nghĩa
`cc_cedict`	125.320	122.742	13.527 / 111.793	han 125.320; en 125.320
`cjkvi_ids`	106.543	87.935	106.543 / 0	han 106.543; không có phần nghĩa
`cjkvi_variants`	60.894	28.509	60.891 / 3	han 60.894; không có phần nghĩa
`dnqatv_wikisource`	70.326	67.657	7.455 / 62.871	qn 62.848, nom 4.384, han 3.094; vi 69.387
`dv`	39.880	16.922	37.953 / 1.927	nom 39.879, qn 1; vi 34.024
`hannom_rcv`	9.125	9.125	7.163 / 1.962	han 7.163, qn 1.962; không có phần nghĩa
`hvdic`	22.765	22.760	22.761 / 4	han 22.765; vi 22.765
`makemeahanzi`	9.574	9.574	9.574 / 0	han 9.574; en 9.516
`moedict`	161.194	161.141	11.330 / 149.864	han 161.194; zh 161.138
`unihan`	102.999	101.997	102.999 / 0	han 102.999; en 23.310
Tổng	**716.727**			

> **Lưu ý**
>
> `btcn`: số thứ tự đã crawl chạy đến 8.187 nhưng chỉ có 8.107 mục từ.

Phân loại nguồn theo ngôn ngữ

Cặp ngôn ngữ	Số nguồn	Nguồn
Hán-Việt (âm Hán Việt)	3	`hvdic`, `dv/giup-doc-nom-va-han-viet`, `catusf` (Thiều Chửu, Từ điển Câu chuyện chữ Hán)
Hán Nôm-Việt	4	`dv` (năm từ điển), `btcn`, `hannom_rcv`, `hvdic` (phần Nôm)
Việt-Việt	2	`dnqatv_wikisource`, `catusf` (Thiều Chửu, Từ điển Hán ngữ)
Hán-Anh	3	`unihan`, `makemeahanzi`, `cc_cedict`

Cặp ngôn ngữ	Số nguồn	Nguồn
Hán-Hán (giải nghĩa bằng tiếng Trung)	1	`moedict`
Trung-Việt (từ ghép)	1	`catusf` (Trung-Việt β)

`cjkvi_ids` và `cjkvi_variants` không có phần nghĩa, chỉ cung cấp cấu tạo chữ và quan hệ dị thể.

Xuất xứ của từng nguồn

Nguồn	Nội dung	Địa chỉ
`unihan`	Chữ CJK: âm đọc (pinyin, Quảng Đông, Hán Việt, Nhật, Hàn), nghĩa tiếng Anh và dị thể.	https://unicode.org/charts/unihan.html
`makemeahanzi`	Chữ Hán: nghĩa tiếng Anh, phân rã chữ, từ nguyên và bộ thủ.	https://github.com/skishore/makemeahanzi
`catusf`	Tập con 5 từ điển lấy từ bộ 65 từ điển StarDict `catusf/tudien`.	https://github.com/catusf/tudien
`cc_cedict`	Từ điển Hán-Anh, chủ yếu là từ ghép.	https://www.mdbg.net/chinese/dictionary?page=cc-cedict
`moedict`	Từ điển Quốc ngữ (tiếng Trung) của Bộ Giáo dục Đài Loan: giải nghĩa chữ và từ bằng tiếng Trung.	https://github.com/g0v/moedict-data
`cjkvi_ids`	Cấu trúc chữ (IDS), không có nghĩa.	https://github.com/cjkvi/cjkvi-ids
`cjkvi_variants`	Quan hệ dị thể giữa các chữ (22 bảng).	https://github.com/cjkvi/cjkvi-variants
`dnqatv_wikisource`	Đại Nam Quấc âm tự vị (1895): từ Quốc ngữ giải nghĩa bằng tiếng Việt, kèm cột chữ Hán và chữ Nôm.	https://vi.wikisource.org/
`hvdic`	Chữ Hán Việt và chữ Nôm, kèm nghĩa tiếng Việt trích từ nhiều từ điển in.	https://hvdic.thivien.net/
`dv`	Năm từ điển Nôm-Việt: `giup-doc-nom-va-han-viet`, `nguyen-trai-quoc-am-tu-dien`, `tu-dien-chu-nom-dan-giai`, `tu-dien-chu-nom-tay`, `taberd`.	https://www.digitizingvietnam.com/en/tools/han-nom-dictionaries/
`btcn`	Chữ Nôm và âm Quốc ngữ tương ứng (Bảng Tra Chữ Nôm).	https://nomfoundation.org/nom-tools/BTCN?uiLang=en
`hannom_rcv`	Bảng chữ Hán Nôm chuẩn, kèm âm đọc.	https://www.hannom-rcv.org/

Các từ điển lấy từ catusf

`catusf` gồm 65 từ điển, trong đó phần lớn là từ điển giữa tiếng Việt với các ngoại ngữ không liên quan đến Hán Nôm. Vì vậy `catusf.jsonl` chỉ giữ 5 từ điển dưới đây. Mỗi mục từ có `id` dạng `catusf:<slug>:<headword>` và trường `extra.dict` bằng đúng `<slug>`.

Mã từ điển (`slug`)	Tên từ điển	Cặp ngôn ngữ	Mục từ (khai báo)
`Tu-dien-ThienChuu-TranVanChanh`	Từ điển từ Hán Việt Thiều Chửu + Trần Văn Chánh	zh-vi	22.030
`TudienThienChuu`	Từ điển từ Hán Việt Thiều Chửu	vi-vi	9.897
`Tu_dien_Han_ngu`	Từ điển Hán ngữ	vi-vi	78.573
`HanziStoriesViet`	Từ điển Câu chuyện chữ Hán bằng tiếng Việt	zh-vi	3.189
`TrungViet-big`	Từ điển Trung-Việt β (đại)	zh-vi	139.043
Tổng			**252.732**

Số mục từ ở đây là số khai báo của từ điển gốc, chưa được đo lại sau khi lọc nên không nằm trong bảng **Độ phủ**.

Mức độ đầy đủ

- **Nguồn tải về trọn bộ** (`unihan`, `makemeahanzi`, `catusf`, `cc_cedict`, `moedict`, `cjkvi_ids`, `cjkvi_variants`): đã parse toàn bộ file và giữ lại mọi bản ghi.
- **Nguồn crawl từ trang web**: `btcn` đã được kiểm tra là đủ, từ số 1 đến trang cuối (không thiếu số nào, các số phía sau đều rỗng). `hvdic` mới chạy xong lượt âm tiết `hv` và `nom`, lượt từ ghép chưa bắt đầu. `dv` đã đo độ phủ theo từng từ điển nhưng chưa chứng minh được là đã lấy hết.

Hạn chế đã biết

- **Chưa loại trùng giữa các nguồn.** Số liệu là số mục từ của từng nguồn, không phải số từ khác nhau; phần trùng chưa được thống kê.
- **Một số nguồn crawl chưa đủ.** `hvdic` (mới xong lượt chữ đơn) và `dv` chưa chứng minh được là đã lấy hết.
- **Số liệu của `catusf` chưa được đo lại.** Đây là số khai báo của từ điển gốc, chưa tính lại sau khi lọc.
- **Chưa xử lý mâu thuẫn** khi các nguồn cho nghĩa hoặc âm đọc khác nhau.
- **Trường `freq` chưa có giá trị**, vì chưa có nguồn nào cung cấp tần suất.
- **Schema v1 chưa hỗ trợ:** ngữ cảnh theo từng sách, tần suất n-gram, thứ tự nét.