Hướng dẫn xây dựng dữ liệu song song Hán Nôm và Quốc ngữ

Thông tin phiên bản

Phiên bản	Ngày cập nhật	Thông tin
v1	28/10/2026	Phiên bản đầu tiên.
v1.1	30/10/2026	Cập nhật quy định về hình ảnh. Thêm phụ lục quy định cho các loại dữ liệu đặc biệt. Thêm thông tin phiên bản.

Tổng quan

- Tài liệu để phổ biến và hướng dẫn chung các nhóm về quy định xây dựng dữ liệu song song Hán Nôm và Quốc ngữ.
- Áp dụng cho loại sách/tài liệu Hán Nôm **đã có bản dịch Quốc ngữ**; phiên bản chụp trắng đen (bản scan), chụp màu; định dạng PDF.
- Đối với các loại sách/tài liệu hoặc phiên bản khác, xem **Phụ lục**.

Quy định chung

- **Trao đổi trực tiếp trên group Zalo** nếu có câu hỏi.
- Liên hệ với người giao tài liệu nếu sách có nhiều trang có chất lượng chưa tốt (rách, mờ,...) với số lượng $>$20% tổng số trang Nôm.
- Luôn làm (dóng hàng) các trang có bản dịch Quốc ngữ, ví dụ các trang bìa Hán Nôm, hoặc mục lục nếu có bản dịch Quốc ngữ thì vẫn làm.
- Luôn làm toàn bộ file sách/tài liệu được giao, ngoại trừ các nhóm được bàn giao sách/tài liệu theo phần hoặc chương.
- Toàn bộ quy trình (pipeline) **khuyến khích làm tự động**, hạn chế làm thủ công, trừ khi các lỗi cần phải sửa tay thủ công.
- Không giới hạn ngôn ngữ lập trình, nhưng ưu tiên Python.
- Không giới hạn mô hình LLM, OCR, công cụ miễn phí hay tính phí,...
- Nếu nhóm đề xuất tự xây dựng mô hình riêng, cần phải cân nhắc thời gian thực hiện để kịp tiến độ.
- **Dữ liệu có thể sẽ được yêu cầu kiểm tra lại nếu chưa đúng yêu cầu hoặc chất lượng chưa tốt**.
- **Yêu cầu độ tương đồng của sách phải đạt tối thiểu là 95% ($\geq$95%)** (Xem **Đánh giá dữ liệu**).
- **Nếu nhóm không thể hoàn thành đúng tiến độ, cần thông báo sớm với các thầy càng sớm càng tốt**.
- Nếu dự án có đính kèm dữ liệu khác có kích thước lớn mà không thể nộp trực tiếp được, có thể lưu trên nền tảng đám mây (**ưu tiên Huggingface**), sau đó liên hệ với các thầy và người bàn giao tài liệu để chia sẻ quyền truy cập vào dữ liệu.

Dữ liệu thô và công cụ hỗ trợ

- Các nhóm sẽ gửi được gửi dữ liệu thô là file sách PDF, các sách này sẽ có bản Nôm và bản dịch Quốc Ngữ, thường là bản dịch âm 1-1.
- Dữ liệu từ điển để hỗ trợ kiểm tra chính tả, hoặc các nhóm có thể tự xây dựng riêng (local hoặc query trực tiếp). Sẽ được gửi sau.
- File hướng dẫn sử dụng API của trang web `https://kimhannom.fit.hcmus.edu.vn/`. Sẽ được gửi sau.

Quy trình thực hiện tổng thể

1. Nhận đề tài và xác nhận phạm vi

Trước khi làm, nhóm phải xác nhận:

- Mã đề tài và tên tác phẩm.
- Quyển, tập, chương hoặc khoảng trang được giao.
- Nguồn Nôm và nguồn Quốc ngữ.
- Định dạng từng nguồn: ảnh, PDF Scan, PDF Text hoặc Text.

> **Lưu ý**
>
> Không bắt đầu OCR hàng loạt nếu chưa chắc hai bản chứa cùng phạm vi nội dung.

> **Lưu ý**
>
> Luôn làm (dóng hàng) các trang có bản dịch Quốc ngữ, ví dụ các trang bìa Hán Nôm, hoặc mục lục nếu có bản dịch Quốc ngữ thì vẫn làm (Xem **Quy định chung**).

2. Kiểm tra nguồn dữ liệu

- Kiểm tra xem chất lượng file sách, nếu có rách, mờ hoặc chất lượng không tốt cần liên hệ người giao tài liệu trước khi thực hiện (Xem **Quy định chung**).

3. Phân loại hình ảnh

- Chia file PDF thành các hình ảnh, đặt tên theo đúng cú pháp (Xem **Quy định chung về file hình ảnh**) (có thể sử dụng pdfslice-py).
- Phân loại hình ảnh vào các thư mục (Xem **Quy định chung về dữ liệu nộp**).
- Tiền xử lý:
  - Kiểm tra hướng của hình ảnh, nếu sai thì phải xoay lại hình ảnh (có thể sử dụng pdfarranger).
  - Tăng chỉnh độ sáng, làm nét hình ảnh,...nếu cần thiết.
- Nếu nhóm có tiền xử lý hình ảnh, theo **Quy định chung về file hình ảnh** thì nhóm phải merge các hình ảnh thành file PDF mới (`<Tên sách>_updated.pdf`) và báo cáo.

4. Chạy OCR hình ảnh

- Cài đặt các mô hình để chạy OCR theo từng ngôn ngữ Nôm hoặc Quốc ngữ.
  - Nôm:
    - Ưu tiên sử dụng công cụ `https://kimhannom.fit.hcmus.edu.vn/` để chạy OCR chữ Nôm, vì đây là công cụ được tinh chỉnh cho dữ liệu Hán Nôm.
    - Có thể dùng các mô hình OCR chữ Hán, hoặc các mô hình OCR đa năng (Xem **Mô hình OCR chữ Nôm**).
    - Hoặc nhóm tự xây dựng mô hình OCR chữ Nôm riêng (cần cân nhắc thời gian thực hiện để kịp tiến độ).
  - Quốc ngữ:
    - Có thể dùng các mô hình OCR chữ Quốc ngữ, hoặc các mô hình OCR đa năng (Xem **Mô hình OCR chữ Quốc ngữ**).
    - Hoặc nhóm tự xây dựng mô hình OCR chữ Quốc ngữ riêng (cần cân nhắc thời gian thực hiện để kịp tiến độ).
- Nên chạy kiểm thử mô hình với vài hình ảnh mẫu (sample) để kiểm tra kết quả.
- Có thể chạy 2–3 mô hình OCR, sau đó sử dụng các kỹ thuật voting để đạt kết quả tốt hơn.

5. Làm sạch dữ liệu

- Map dữ liệu OCR theo định dạng của PPOCRLabel (Xem **Quy định chung về file OCR**).
- Kiểm tra bounding box, loại bỏ các bounding box không cần thiết (Xem **Quy định chung về việc đánh bounding box**).
- Làm sạch dữ liệu văn bản (Xem **Quy định chung về dữ liệu văn bản**).
- Kiểm tra lỗi chính tả, sửa lỗi nếu cần thiết:
  - Có thể dùng từ điển (Xem **Nguồn từ điển**).
  - Hoặc các công cụ kiểm tra chính tả (Xem **Mô hình kiểm tra chính tả (Spellcheck)**).

6. Dóng hàng dữ liệu

- Ghép từ/câu bị ngắt do chuyển trang trước khi thực hiện việc tách câu.
- Xây dựng mô hình để dóng hàng dữ liệu (Xem **Mô hình dóng hàng Nôm – Quốc ngữ**).
- Dóng hàng dữ liệu theo định dạng file `<Tên sách>.csv` và `<Tên sách>.xlsx` (Xem **Quy định chung về việc dóng hàng**).

7. Đánh giá dữ liệu

- Kiểm tra độ tương đồng giữa chữ Nôm và chữ Quốc ngữ (Xem **Đánh giá dữ liệu**).

8. Nộp dữ liệu

- Kiểm tra dữ liệu trước khi nộp, đảm bảo các file đúng định dạng, không bị lỗi font, không bị lệch cột, không bị trùng lặp hình ảnh,...
- Nộp dữ liệu theo đúng cấu trúc (Xem **Quy định chung về dữ liệu nộp**).

Quy định chung về dữ liệu nộp

```
<MSSV1_MSSV2_MSSV3_MSSV4>.zip/
|-- <Tên sách>/
|   |-- ch/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label_char.txt (nếu có)
|   |   |-- fileState_char.txt (nếu có)
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- vi/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- intro/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- ref/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- toc/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- blank/
|   |   `-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |-- misc/
|   |   `-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |-- <Tên sách>.pdf
|   |-- <Tên sách>_updated.pdf (nếu có)
|   |-- <Tên sách>.xlsx (dữ liệu đã dóng hàng)
|   `-- <Tên sách>.csv (dữ liệu đã dóng hàng)
|-- <MSSV1_MSSV2_MSSV3_MSSV4>_report.pdf (dựa theo tên file zip)
|-- source.zip
`-- extras.zip (dữ liệu thêm,...)
```

Chú thích

- **Tên file zip**: Do các thầy phổ biến. Mặc định: `MSSV1_MSSV2_MSSV3_MSSV4.zip`.
- Thư mục `<Tên sách>`: Thư mục chứa dữ liệu của sách
  - **Tên sách phải giữ theo tên file sách PDF được giao**, trừ khi có sự cập nhật từ phía người bàn giao.
  - Ví dụ trong quá trình xử lý tên sách `Lorem ipsum` được chuyển thành `Lorem%20ipsum`, thì dữ liệu nộp phải chuyển lại `Lorem ipsum` y như tên sách được giao.
  - **Quy định này áp dụng cho toàn bộ dữ liệu nộp**.
- Thư mục `vi` (**bắt buộc có**): Thư mục chứa các trang Quốc Ngữ
  - Tên hình ảnh `<Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg`.
  - File dữ liệu OCR `Label.txt`, theo format của PPOCRLabel (Xem **Quy định chung về file OCR**).
  - File tiến trình đánh nhãn `fileState.txt`, theo format của PPOCRLabel (Xem **Quy định chung về file OCR**).
- Thư mục `ch` (**bắt buộc có**): Thư mục chứa các trang Hán Nôm
  - Cấu trúc giống như thư mục `vi`.
  - File dữ liệu OCR theo từng chữ `Label_char.txt` (nếu có), theo format của PPOCRLabel (Xem **Quy định chung về file OCR**).
  - File tiến trình đánh nhãn theo từng chữ `fileState_char.txt` (nếu có), theo format của PPOCR-Label (Xem **Quy định chung về file OCR**).

- Thư mục `intro` (không bắt buộc làm): Thư mục chứa các trang giới thiệu, nếu có
  - Cấu trúc giống như thư mục `vi`.
- Thư mục `ref` (không bắt buộc làm): Thư mục chứa các trang chú thích, nếu có
  - Cấu trúc giống như thư mục `vi`.
- Thư mục `toc` (không bắt buộc làm): Thư mục chứa các trang mục lục, nếu có
  - Cấu trúc giống như thư mục `vi`.
- Thư mục `blank`: Thư mục chỉ chứa các trang trắng, các trang không có dữ liệu cần OCR (ví dụ: trang có khung khắc in Nôm nhưng không có chữ nào), nếu có.
- Thư mục `misc`: Thư mục chứa các trang còn lại, thường là trang bìa hoặc không liên quan.
- File `<Tên sách>.pdf` (**bắt buộc có**): **File tài liệu gốc** mà nhóm được bàn giao.
- File `<Tên sách>_updated.pdf`: File tài liệu mà nhóm đã chỉnh sửa (nếu có).
- File `<Tên sách>.xlsx` (**bắt buộc có**): Xem **Quy định chung về việc dóng hàng**.
- File `<Tên sách>.csv` (**bắt buộc có**): Xem **Quy định chung về việc dóng hàng**.
- File `<MSSV1_MSSV2_MSSV3_MSSV4>_report.pdf` (**bắt buộc có**): Xem **Quy định chung về file báo cáo**.
- File `source.zip` (**bắt buộc có**): Xem **Quy định chung về mã nguồn**.
- File `extras.zip`: Dữ liệu thêm. Không có quy định cụ thể, nhưng cần nêu rõ trong báo cáo.

Quy định chung về file hình ảnh

- Cú pháp: `<Tên sách>.<Số thứ trang>[_<Số thứ tự hình ảnh>].jpg`.
- `<Số thứ tự trang>`:
  - Gồm ít nhất 3 số, **với số thứ tự đánh từ số 1, tính từ trang đầu tiên của file PDF**. Ví dụ `Lorem ipsum.001.jpg`, `Lorem ipsum.011.jpg`, `Lorem ipsum.111.jpg`.
  - Nếu số trang của sách lớn hơn 999 thì để không thêm chữ số 0 ở đầu nữa, ví dụ `Lorem ipsum.1234.jpg`, `Lorem ipsum.123456.jpg`,...
- `[_<Số thứ tự hình ảnh>]`:
  - Chỉ thêm số thứ tự hình ảnh khi có nhiều hơn 1 ảnh chụp Hán Nôm trong trang.
  - Đánh dấu số thứ tự hình ảnh: từ trái sang phải, từ trên xuống dưới.
  - Gồm ít nhất 1 số, **với số thứ tự đánh từ số 1, tính từ hình đầu tiên trong trang**. Ví dụ `Lorem ipsum.001_1.jpg`, `Lorem ipsum.001_10.jpg`, `Lorem ipsum.001_100.jpg`.
- Định dạng hình ảnh (extension): `.jpg` (JPEG). Không sử dụng định dạng hình ảnh khác.
- Toàn bộ hình ảnh (kể cả trang trắng, trang bìa,...) phải được kiểm tra và chỉnh sửa nếu bị sai hướng. Có thể dựa vào số trang, chữ viết hoặc gáy sách để xác định hướng của hình ảnh.
- Một hình ảnh có thể thuộc 1 hoặc nhiều thư mục khác nhau, ví dụ 1 hình ảnh đều thuộc thư mục `ch` hoặc `vi` (trường hợp hình ảnh có Nôm và Quốc ngữ lẫn lộn, xem ở dưới), nhưng khi merge lại file PDF phải **đảm bảo là không có hình ảnh trùng lặp**.
- **Hình ảnh được chia từ file PDF phải có độ phân giải càng cao càng tốt**. Ví dụ ảnh gốc ở file PDF có độ phân giải 3144 x 2096 thì khi chiết ra vẫn giữ độ phân giải 3144 x 2096.
- Nếu nhóm có bất kỳ thay đổi gì về hình ảnh, như chỉnh độ sáng, xoay trang, làm nét ảnh,...**cần phải merge thành file PDF mới**, gửi cùng với file thư mục (như đã quy định ở mục **Cấu trúc file** nộp) và **thông báo với người giao sách là có thay đổi về nội dung file PDF**.

> **Lưu ý**
>
> Công cụ PPOCRLabel không được tối ưu cho hình ảnh có độ phân giải cao, nên có thể rescale về 1K để đánh dấu, sau đó căn cứ vào scale để upscale bbox lại về với độ phân giải ban đầu.

Quy định chung về file OCR

- Với thư mục `vi` và `ch`, sẽ bao gồm chủ yếu hai file `Label.txt` và `fileState.txt` theo định dạng của PPOCRLabel:
  - **`Label.txt`**: File dữ liệu gồm toạ độ bounding box và văn bản đã nhận diện, mỗi hàng (`\n`) là dữ liệu bounding box cho một hình ảnh:
    - Phần đầu là đường dẫn hình ảnh (image path): cú pháp `<folderName>/<imageName>`. Ví dụ với hình ảnh `a.jpg` nằm trong thư mục `foo`, khi dùng công cụ PPOCRLabel để mở thư mục `foo` thì file `Label.txt` sẽ được lưu tại `foo/Label.txt` và đường dẫn hình ảnh trong `Label.txt` sẽ có cú pháp `foo/a.jpg`.
    - Phần sau là dữ liệu bounding box: mảng chứa các đối tượng (array object) với yêu cầu có 2 trường chính là `transcription` (văn bản nhận dạng) và `points` (toạ độ các điểm của bounding box).
    - **Mỗi box chỉ có đúng 4 điểm**, không được ít hơn hoặc nhiều hơn.
    - Hai phần được cách nhau bởi ký tự `\t` (tab).
    - **Nội dung `transcription` phải được làm sạch** và tuân thủ theo **Quy định chung về dữ liệu văn bản**.

      > **Lưu ý**
      >
      > Ngoài hai trường chính là `transcription` và `points`, có thể thêm có trường khác (như confident, score,...) nhưng phải có chú thích rõ.

  - **`fileState.txt`**: File tiến trình đánh nhãn, mỗi hàng (`\n`) là tình trạng đánh nhãn cho một hình ảnh:
    - Phần đầu là đường dẫn hình ảnh (image path) có cú pháp giống như trong file `Label.txt`
    - Phần sau là tình trạng gán nhãn, `1` là đã hoàn thành, `0` là chưa hoàn thành.
    - Hai phần được cách nhau bởi ký tự `\t` (tab).
  - **`Label_char.txt`** (nếu có): File dữ liệu gồm toạ độ bounding box cho từng chữ Hán Nôm.
  - **`fileState_char.txt`** (nếu có): File tiến trình đánh nhãn cho từng chữ Hán Nôm.

`Label.txt` — mỗi ảnh là **một dòng** trong file; `TAB` là ký tự tab (`\t`), `LF` là ký tự xuống dòng (`\n`). Việc ngắt dòng bên dưới chỉ do khổ giấy, không có trong file thật.

```
vi/Lorem ipsum.024.jpg TAB [{"transcription":"Lorem
     ipsum","points":[[249,361],[1064,361],[1064,465],[249,465]]},{"transcription":"Lorem
     ipsum","points":[[254,540],[1068,540],[1068,878],[254,878]]}] LF
vi/Lorem ipsum.025.jpg TAB [{"transcription":"Lorem
     ipsum","points":[[249,361],[1064,361],[1064,465],[249,465]]},{"transcription":"Lorem
     ipsum","points":[[254,540],[1068,540],[1068,878],[254,878]]}] LF
```

Cùng một dòng của ảnh `vi/Lorem ipsum.024.jpg`, trình bày lại cho dễ đọc (*chỉ để minh hoạ*, trong file thật phải nằm trên một dòng):

```
vi/Lorem ipsum.024.jpg          <- (1) đường dẫn ảnh: <folderName>/<imageName>
TAB                             <- (2) ký tự tab ngăn cách
[                               <- (3) mảng JSON, mỗi phần tử là một bounding box
  { "transcription": "Lorem ipsum",
    "points": [[249,361], [1064,361], [1064,465], [249,465]] },   <- đúng 4 điểm
  { "transcription": "Lorem ipsum",
    "points": [[254,540], [1068,540], [1068,878], [254,878]] }
] LF
```

`fileState.txt` — sau tab là `1` (đã hoàn thành) hoặc `0` (chưa hoàn thành):

```
vi/Lorem ipsum.024.jpg TAB 1 LF
vi/Lorem ipsum.025.jpg TAB 1 LF
```

Quy định chung về việc đánh bounding box

- Các bounding box phải ôm sát, tránh để bị lệch các hàng, chữ.
- Bỏ qua các bảng biểu và tranh/ảnh nếu có.
- Loại bỏ các dữ liệu không cần thiết trong trang như: số trang (cả số trang Nôm và Quốc ngữ), tiêu đề (cả Nôm và Quốc ngữ), chân trang,...
- Trang Nôm (**ưu tiên**):
  - Cấp độ: Đánh **theo từng cột dọc**. Nếu chữ Nôm được viết ngang thì đánh theo hàng.
  - Đối với các hàng chữ Nôm được cách ra (có khoảng trắng giữa các chữ trong cột) thì đánh 1 box riêng, không gộp chung.
  - Đối với các chữ Nôm được ghép từ 2 ký tự hàng ngang, đánh 2 box riêng biệt.
- Trang Quốc ngữ:
  - Cấp độ: Nếu công cụ có hỗ trợ thì đánh box **theo hàng** (cột ngang) hoặc **theo đoạn**, còn không thì đánh 1 box cho **toàn trang**.
- Thứ tự bounding box:
  - Nôm: từ phải sang trái, từ trên xuống dưới. Nếu chữ Nôm được viết ngang thì từ trái sang phải, từ trên xuống dưới
  - Quốc ngữ: từ trái sang phải, từ trên xuống dưới.
- Nếu có dữ liệu bounding box cho từng chữ Nôm, lưu thành hai file riêng `Label_char.txt` và `fileState_char.txt` (Xem **Quy định chung về file OCR**).
- **Yêu cầu phải đánh nhãn cho toàn bộ hình ảnh có trong thư mục, hoặc theo phần/chương được giao**.

> **Lưu ý**
>
> Phải đảm bảo các file đúng định dạng của PPOCRLabel, mở và xem được trên công cụ PPOCR-Label.

Các trường hợp đặc biệt

*Xem **Phụ lục - Chú thích về phân loại sách** để biết về các phân loại sách.*

- **Bản chụp 1 trang**:
  - Nôm và Quốc ngữ lẫn lộn (thường là phân loại T2b, T2bw):
    - Lưu hình ảnh cho cả hai thư mục `ch` và `vi`. Hình ảnh trong `ch` thì chỉ giữ lại các bounding box Nôm và ngược lại, hình ảnh trong `vi` chỉ giữ lại các bounding box Quốc ngữ.
    - Thứ tự bounding box vẫn theo như trên, bởi vì đã loại bỏ các bounding box không cùng ngôn ngữ.
- **Bản chụp 2 trang** (trang trái trước, phải sau):
  - Nôm – Nôm (thường là phân loại T1, T1w, Tnom, Tnomw):
    - Thứ tự bounding box: cột đầu tiên bên phải của trang trái tính là 1, đánh thứ tự tiếp theo từ phải sang trái như bình thường cho trang trái, sau đó là cột đầu tiên bên phải của trang phải.
    - Nếu Nôm viết ngang thì xử lý như trường hợp Quốc ngữ – Quốc ngữ.
  - Quốc ngữ – Quốc ngữ (thường là T1, T1w, Tqn): hàng đầu tiên của trang trái tính là 1, đánh thứ tự tiếp theo từ trên xuống dưới như bình thường cho trang trái, sau đó là hàng đầu tiên của trang phải.
  - Nôm – Quốc ngữ (thường là phân loại T2, T2w): xử lý như bản chụp 1 trang.

Quy định chung về dữ liệu văn bản

- Bỏ đầu trang, chân trang và các trang không thuộc nội dung chính.
- Loại dòng trùng do OCR lặp vùng.
- Loại bỏ chú thích nằm ngoài nội dung chính, bao gồm chú thích ở chân trang, các chỉ mục chú thích chèn trong nội dung chính (như [1], (1) v.v..).
- Sửa ký tự rác và khoảng trắng bất thường.
- Chuẩn hóa dấu câu nhưng không thay đổi nghĩa.
- Giữ tên riêng, niên hiệu, con số và đơn vị đo theo nguồn.
- Nôm:
  - Các chữ viết dính liền, không có khoảng trắng. Sử dụng các dấu phù hợp, ví dụ 、 (dấu phẩy), 。(dấu chấm),...
  - Ký tự hợp lệ, có thể xem được bằng các font chữ Hán Nôm được đề cập trong phần thông tin tham khảo.
- Quốc ngữ:
  - Đúng chính tả, các chữ tuân theo quy cách Tiếng Việt thông thường, ví dụ khoảng trắng sau dấu phẩy, dấu chấm,...

Quy định chung về việc dóng hàng

Tách câu

- **Ghép từ/câu bị ngắt do chuyển trang** trước khi thực hiện việc tách câu.
- Nôm:
  - Dùng 。!?; làm gợi ý, không coi là quy tắc tuyệt đối.
  - Văn bản cổ có thể không có dấu câu hoặc dấu câu do người biên tập thêm.
- Quốc ngữ:
  - Dùng `.?!;:` kết hợp cấu trúc ngữ nghĩa.
  - Chú ý chữ viết tắt, số thứ tự và tên riêng có dấu chấm.
  - Bản dịch có thể gộp hoặc diễn giải nhiều câu Nôm.

Cấu trúc file dóng hàng (align)

- Cấu trúc file `<Tên sách>.csv`:

Tên cột	Chú thích
`img_id`	Tên hình ảnh, không chứa tên thư mục
`sentence_id`	**Số thứ tự câu Nôm trong các trang Nôm**, với số thứ tự đánh từ 1. **Bắt buộc theo định dạng `<img_id bỏ đuôi .jpg>.<số thứ tự câu>`**, ví dụ `Lorem ipsum.024.1`
`SinoNom_Char`	Văn bản Hán Nôm
`ChuQN_txt`	Văn bản Quốc ngữ

- Ví dụ:

img_id	sentence_id	SinoNom_Char	ChuQN_txt
Lorem ipsum.024.jpg	Lorem ipsum.024.1	経申母福。	Kinh Thân Mẫu Phúc.
Lorem ipsum.024.jpg	Lorem ipsum.024.2	経福実糝綿。	Kinh Phúc Thật Tám Mối.
Lorem ipsum.025.jpg	Lorem ipsum.025.1	経告命。	Kinh Cáo Mình.
Lorem ipsum.026_1.jpg	Lorem ipsum.026_1.1	経天主。共経亞蝸。	Kinh Thiên Chúa. cùng kinh A-ve.

- Cấu trúc file `<Tên sách>.xlsx`:
  - Cấu trúc giống như Cấu trúc file `<Tên sách>.csv`.
  - Tô màu chữ Nôm và chữ Quốc ngữ để thể hiện tình trạng dóng hàng:
    - Màu đen (**bắt buộc**): Chữ Nôm và chữ Quốc ngữ giống nhau về nghĩa (có thể dùng từ điển để kiểm tra).
    - Màu đỏ (**bắt buộc**): Chữ Nôm và chữ Quốc ngữ khác nhau về nghĩa (có thể dùng từ điển để kiểm tra).
    - Chữ Nôm không tìm thấy trong từ điển cũng được tính là sai: tô màu đỏ (cho cả chữ Nôm và chữ Quốc ngữ tương ứng).
    - Ví dụ:
      - Chữ 一 và `nhất` giống nghĩa nhau → tô màu đen cho cả hai chữ.
      - Chữ 一 và `nhị` khác nghĩa nhau → tô màu đỏ cho cả hai chữ.

Các kiểu dóng hàng được chấp nhận

- `1--1`: một câu/đoạn Nôm tương ứng một câu/đoạn Việt.
- `1--n`: một đơn vị Nôm tương ứng nhiều câu Việt; gộp các câu Việt liên quan vào cùng một ô.
- `n--1`: nhiều câu Nôm tương ứng một câu Việt; gộp các câu Hán liên quan vào cùng một ô.
- `n--m`: chỉ dùng khi bản dịch tái cấu trúc mạnh và không thể tách nhỏ hơn mà vẫn giữ đúng nghĩa.

> **Lưu ý**
>
> Ưu tiên đơn vị nhỏ nhất có ý nghĩa đầy đủ. Không chia cơ học theo dấu câu nếu việc chia làm mất quan hệ dịch.

Tiêu chí một cặp dóng hàng đúng

- Một cặp được xem là đúng khi:
  1. Hai vế nói về cùng nội dung.
  2. Không bỏ mất ý quan trọng.
  3. Không thêm nội dung thuộc câu/đoạn khác.
  4. Tên riêng, chức danh, địa danh cơ bản tương ứng.
  5. Thời gian, niên hiệu và con số tương ứng.
  6. Ranh giới câu/đoạn hợp lý.
  7. Không phải dòng tiêu đề, số trang hoặc OCR rác ghép nhầm.
- **Nếu là dịch âm thì số chữ Quốc ngữ phải bằng số chữ Hán Nôm**.
- Nếu không phải là dịch âm thì bản dịch không cần sát từng chữ; đánh giá dựa trên quan hệ dịch và phạm vi nội dung.

Quy định chung về file báo cáo

- Tên file báo cáo dựa trên tên file zip theo các thầy đã phổ biến.
- Thông tin của từng thành viên: họ tên, mssv, email sinh viên.
- **Cấu trúc báo cáo dựa theo hướng dẫn của các thầy (nếu có)**. Có thể viết bằng Word, Google Docs, Latex,...**miễn là file PDF là được**.
- Mô tả các việc nhóm đã làm, như thiết lập mô hình, cào dữ liệu,...
- Phần trích dẫn (nếu có).

> **Lưu ý**
>
> Phần phụ lục phải đính kèm các hình ảnh như sau:
> - Ảnh chụp mẫu một trang Hán Nôm mở được bằng công cụ PPOCRLabel (kiểm tra xem có đúng format, bounding box có đúng vị trí hay không).
> - Ảnh chụp mẫu một trang Quốc ngữ mở được bằng công cụ PPOCRLabel (kiểm tra xem có đúng format, bounding box có đúng vị trí hay không).
> - Ảnh chụp mẫu trang tính (.xlsx) cho thấy file mở được và không bị lỗi font.
> - Ảnh chụp mẫu trang tính (.csv) cho thấy file mở được và không bị lệch cột.

Quy định chung về mã nguồn

- Không giới hạn ngôn ngữ lập trình như đã đề cập ở phần **Quy định chung**, nhưng **ưu tiên Python**.
- File **README.md**:
  - Mô tả chi tiết dự án.
  - Chú thích rõ môi trường mà dự án đã chạy, như phiên bản Python, OS (**ưu tiên Ubuntu**), RAM, cấu hình đồ hoạ,...
- Các thư viện cài đặt (dependencies) **PHẢI** được cố định (pinned).
- File **USER_GUIDE.md**:
  - **Mô tả chi tiết cách chạy dự án từ đầu đến cuối** (cách cài thư viện, chạy lệnh,...) như trên một máy tính mới, **với dữ liệu mà nhóm đã nộp**.
  - Đối với các công cụ/mô hình có tính phí cũng cần được chú thích đầy đủ về mô hình, prompt đã sử dụng, cách cài đặt (token,...).

Đánh giá dữ liệu

- Dữ liệu được đánh giá dựa trên phần trăm độ tương đồng của từ chữ Nôm và chữ Quốc ngữ:

$$\textbf{độ tương đồng (\%)} = \left(1 - \frac{\text{tổng số chữ không tương đồng (chữ đỏ)}}{\text{tổng số chữ}}\right) \times 100$$

- **Yêu cầu độ tương đồng của sách phải đạt tối thiểu là 95% ($\geq$95%)**.

Thông tin tham khảo

> **Lưu ý**
>
> Các thông tin dưới đây **chỉ mang tính chất tham khảo**, không bắt buộc các nhóm phải sử dụng.

Mô hình OCR chữ Nôm

Tên mô hình / Công cụ	Liên kết tài nguyên
Công cụ chuyển tự và OCR Hán Nôm (Ưu tiên)	Website
PP-OCRv5 (Baidu)	GitHub | ArXiv | Demo
HunyuanOCR (Tencent)	Huggingface
PaddleOCR-VL (Baidu)	ArXiv | Weights | GitHub
GLM-OCR (Z.ai)	Huggingface
HanDoc-OrderOCR	GitHub
Qwen2.5-VL-7B-Instruct (Alibaba)	Huggingface
Qianfan-OCR (Baidu)	Huggingface
Qwen3.5-9B (Alibaba)	Huggingface

> **Lưu ý**
>
> Vì sao có thể dùng tạm mô hình OCR chữ Hán cho dữ liệu Hán Nôm:
> - Chữ Nôm được người Việt tạo ra dựa trên chữ Hán (mượn nguyên chữ Hán hoặc ghép từ các thành phần chữ Hán), và văn bản Hán Nôm cũng chứa nhiều chữ Hán thuần, nên phần lớn chữ, nét và bộ thủ đã nằm trong tập ký tự mà mô hình OCR chữ Hán học được.
> - Hạn chế: chữ Nôm tự tạo mà mô hình chưa từng gặp dễ bị nhận sai hoặc bỏ sót, và các mô hình này chưa được tinh chỉnh cho bản in hoặc bản viết tay cổ, nên kết quả cần được đối chiếu với từ điển và sửa tay.

Mô hình OCR chữ Quốc ngữ

Tên mô hình / Công cụ	Liên kết tài nguyên
MonkeyOCRv2	GitHub | Paper
HunyuanOCR (Tencent)	Huggingface
PaddleOCR-VL (Baidu)	ArXiv | Weights | GitHub
dots.ocr (rednote-hilab)	Huggingface
Qwen2.5-VL-7B-Instruct (Alibaba)	Huggingface
Vintern-1B-v2 (5CD-AI)	Huggingface
Qianfan-OCR (Baidu)	Huggingface
Qwen3.5-9B (Alibaba)	Huggingface

Mô hình dóng hàng Nôm – Quốc ngữ

Công trình / Phương pháp & Tác giả	Liên kết tài nguyên
Ancient-Modern Chinese Translation Liu, Lv, Yang, Qu (ACM TALLIP)	ArXiv | DOI
Transliterating Nôm Scripts into Vietnamese Dinh, Nguyen, Nguyen (IJACSA, vol. 12, no. 2, 2021)	Paper PDF
SentAlign Steingrímsson, Loftsson, Way (EMNLP 2023 Demo)	ACL Anthology | GitHub
Bertalign Liu & Zhu (Digital Scholarship in the Humanities, 2022)	DOI | PyPI
Vecalign Thompson & Koehn (EMNLP-IJCNLP 2019)	ACL Anthology

Mô hình kiểm tra chính tả (Spellcheck)

Phân loại	Tên mô hình / Công cụ	Mô tả chi tiết	Liên kết tài nguyên
Hán / Hán Nôm	**SCOPE**	Kiểm tra chính tả tiếng Trung	ArXiv | GitHub | Checkpoint
Hán / Hán Nôm	**ReaLiSe**	Mô hình sửa lỗi chính tả tiếng Trung	ACL | GitHub | Checkpoint
Quốc ngữ	**BARTpho**	Mô hình ngôn ngữ tiếng Việt (syllable)	Huggingface
Quốc ngữ	**ViSoBERT**	Mô hình BERT tiếng Việt	Huggingface

Nguồn từ điển

Tên từ điển	Ngôn ngữ / Phạm vi hỗ trợ	Liên kết tài nguyên
Nôm Na Việt	Chữ Hán Nôm – Quốc ngữ (âm đọc)	Website
Unihan (Unicode Consortium)	Chữ Hán/CJK, âm Hán-Việt, Quan thoại, Quảng Đông, Nhật, Hàn, nghĩa Anh	Mô tả | Dữ liệu Unihan.zip
Bảng chữ Hán Nôm chuẩn (Hannom-RCV)	Chữ Hán Nôm – Quốc ngữ (âm đọc)	Website

Tên từ điển	Ngôn ngữ / Phạm vi hỗ trợ	Liên kết tài nguyên
Bảng Tra Chữ Nôm (Quỹ BT Di sản Nôm)	Chữ Nôm – Quốc ngữ	Website
Digitizing Vietnam	Bộ từ điển Hán Nôm	Website
HVDIC	Hán-Việt và Nôm – tiếng Việt	Website
Đại Nam Quấc âm tự vị (1895)	Quốc ngữ – Quốc ngữ, có kèm Hán Nôm (Wikisource)	Wikisource
Wiktionary tiếng Việt	Việt – Việt, có bảng Hán-Việt và Nôm	Website
Wiktionary tiếng Anh (Kaikki.org)	Đa ngôn ngữ (Trung, Việt, Nhật, Hàn…), giải nghĩa tiếng Anh	Website
CC-CEDICT	Trung – Anh	Website
CC-Canto	Âm Quảng Đông (Jyutping) cho CC-CEDICT	Download
Make Me a Hanzi	Chữ Hán, nghĩa tiếng Anh, cấu tạo, từ nguyên, bộ thủ	GitHub
cjkvi-ids & cjkvi-variants	Chữ Hán/CJK, cấu trúc ký tự và quan hệ dị thể	cjkvi-ids | cjkvi-variants
MOE Revised Mandarin Dictionary	Quan thoại (Đài Loan) – Quan thoại	GitHub
ERDRG (JMdict, KANJIDIC2)	Nhật – Anh, kanji	Website
Kengdic	Hàn – Anh	GitHub
vdict	Anh – Việt, Việt – Anh, Việt – Việt	Website
vtudien	Anh – Việt, Trung – Việt, Việt – Trung, Việt – Việt	Website

Font chữ

Tên font	Mô tả & Hướng dẫn	Liên kết tài nguyên
HAN NOM A, HAN NOM B (VietUnicode)	Font chữ Hán Nôm tiêu chuẩn	Mô tả | Tải về
Nom Na Tong Light (Quỹ Bảo tồn Nôm)	Font chữ Nôm chuyên dụng	Hướng dẫn | Nom Foundation
Han-Nom Gothic, Han-Nom Ming, Han-Nom Kai	Hannom-RCV	Website
HanaMin A, HanaMin B	Font chữ CJK/Hán Nôm rộng	Hướng dẫn
MingLiU, MingLiU-ExtB	Font hệ thống hỗ trợ ExtB	Website

Công cụ hỗ trợ

Tên công cụ	Mô tả chức năng chính	Liên kết tài nguyên
PPOCRLabel	Hỗ trợ đánh dấu bounding box cho OCR	GitHub
pdfarranger	Hỗ trợ sắp xếp/chỉnh sửa file PDF (Linux)	GitHub
pdfslice-py	Hỗ trợ chia trang file PDF	GitHub

Phụ lục

Chú thích về phân loại sách

Code (Mã)	Layout & Script Description (Mô tả bố cục & chữ viết)
T1	Quốc ngữ nằm ở phần đầu, Nôm ở phần cuối. Thứ tự đọc trang Quốc ngữ từ trái sang phải, thứ tự đọc trang Hán Nôm từ phải sang trái. Ví dụ: trang 1 QN là bản dịch của trang 10 HN, trang 2 QN là bản dịch của trang 9 HN. Cũng có trường hợp 1 trang QN là bản dịch của 2 trang HN.
T1w	T1 nhưng viết tay Nôm (w là writing)
T2	Xen kẽ (Ví dụ: Phải: Nôm, Trái: Quốc Ngữ)
T2w	T2 nhưng viết tay Nôm (w là writing)
T2b	Quốc ngữ và Nôm chung trang
Tref	Tham khảo
Tx	Loại khác
Tqn	Chỉ có Quốc ngữ
Tnom	Chỉ có Nôm
Tnomw	Chỉ có viết tay Nôm (w là writing)
Chưa phân loại	Chưa phân loại

Loại dữ liệu văn bản thuần

Đối với loại tài liệu văn bản thuần chỉ có văn bản Hán Nôm và văn bản Quốc ngữ, không có hình ảnh sẽ có vài thay đổi về cấu trúc dữ liệu nộp và cấu trúc file dóng hàng.

Cấu trúc dữ liệu nộp - Loại dữ liệu văn bản thuần

```
<MSSV1_MSSV2_MSSV3_MSSV4>.zip/
|-- <Tên sách>/
|   |-- <Tên sách>.xlsx (dữ liệu đã dóng hàng)
|   `-- <Tên sách>.csv (dữ liệu đã dóng hàng)
|-- <MSSV1_MSSV2_MSSV3_MSSV4>_report.pdf (dựa theo tên file zip)
|-- source.zip
`-- extras.zip (dữ liệu thêm,...)
```

Quy định về việc đánh bounding box - Loại dữ liệu văn bản thuần

Không có hình ảnh nên không đánh bounding box.

Cấu trúc file dóng hàng (align) - Loại dữ liệu văn bản thuần

- Cấu trúc file `<Tên sách>.csv`:

Tên cột	Chú thích
`sentence_id`	**Số thứ tự câu Nôm**, với số thứ tự đánh từ 1
`SinoNom_Char`	Văn bản Hán Nôm
`ChuQN_txt`	Văn bản Quốc ngữ

- Ví dụ:

sentence_id	SinoNom_Char	ChuQN_txt
1	経申母福。	Kinh Thân Mẫu Phúc.
2	経福実糝緡。	Kinh Phúc Thật Tám Mối.
3	経告命。	Kinh Cáo Mình.

- Cấu trúc file `<Tên sách>.xlsx`:
  - Cấu trúc giống như Cấu trúc file `<Tên sách>.csv`.

Loại dữ liệu hình ảnh chưa được ghép thành file PDF

Đối với loại dữ liệu hình ảnh chưa được ghép thành file PDF, được chia làm các loại chính:

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn. Có thể dịch theo toàn trang, theo từng cột hoặc theo từng chữ.
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**: thường là tài liệu dịch nghĩa của tài liệu Hán Nôm, ít phổ biến hơn, thường là sách cũ.

Quy định về việc ghép hình ảnh - Loại dữ liệu hình ảnh chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Sắp xếp hình ảnh vào thư mục `ch` như đã quy định.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `Tnom_<Tên sách>.pdf` hoặc `Tnomw_<Tên sách>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Sắp xếp hình ảnh vào thư mục `ch` như đã quy định.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `Tnom_<Tên sách>.pdf` hoặc `Tnomw_<Tên sách>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Sắp xếp hình ảnh vào thư mục `ch` và `vi` như đã quy định.
  - Sắp xếp bản dịch Quốc ngữ ở phần đầu, hình ảnh chụp Hán Nôm ở phần sau tài liệu.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `T1_<Tên sách>.pdf` hoặc `T1w_<Tên sách>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).

> **Lưu ý**
>
> Đối với hình ảnh được thu thập trên mạng, luôn đảm bảo hình ảnh thu thập có độ phân giải cao nhất.

Cấu trúc dữ liệu nộp - Loại dữ liệu hình ảnh chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Cấu trúc dữ liệu nộp không có thư mục `vi`.
  - Xem **Quy định chung về dữ liệu nộp**.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Cấu trúc dữ liệu nộp không có thư mục `vi`.
  - Xem **Quy định chung về dữ liệu nộp**.
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Cấu trúc dữ liệu nộp có đủ thư mục `ch` và `vi`.
  - Xem **Quy định chung về dữ liệu nộp**.

Quy định về việc đánh bounding box - Loại dữ liệu hình ảnh chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Chỉ đánh bounding box cho hình ảnh trong thư mục `ch`.
  - Xem **Quy định chung về việc đánh bounding box**.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Chỉ đánh bounding box cho hình ảnh trong thư mục `ch`.
  - Xem **Quy định chung về việc đánh bounding box**.

  > **Lưu ý**
  >
  > Văn bản Hán Nôm phải được tách ra để khớp với dữ liệu bounding box.

- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Đánh bounding box cho hình ảnh trong thư mục `ch` và `vi`.
  - Xem **Quy định chung về việc đánh bounding box**.

Cấu trúc file dóng hàng (align) - Loại dữ liệu chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Quy định chung về việc dóng hàng**.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Quy định chung về việc dóng hàng**.
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Xem **Quy định chung về việc dóng hàng**.

Loại tài liệu đánh máy (file PDF)

Đối với loại tài liệu đánh máy (file PDF), được chia làm các loại chính:

- **Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn. Chữ Nôm được đánh ngang.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn. Có thể dịch theo toàn trang, theo từng cột hoặc theo từng chữ. Chữ Nôm được đánh ngang.

Quy định về việc ghép hình ảnh - Loại tài liệu đánh máy (file PDF)

- **Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Không có hình ảnh chụp Hán Nôm nên không xử lý.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Nếu ảnh chụp Hán Nôm nằm chung trang với văn bản Hán Nôm hoặc bản dịch Quốc ngữ (thường là T2b):
    - Cắt hình ảnh thành từng file riêng.
    - Thêm `[_<Số thứ tự hình ảnh>]` cho tên file (Xem **Quy định chung về file hình ảnh**).
  - Sắp xếp hình ảnh vào thư mục `ch` như đã quy định.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `Tnom_<Tên sách>.pdf` hoặc `Tnomw_<Tên sách>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).

Cấu trúc dữ liệu nộp - Loại tài liệu đánh máy (file PDF)

- **Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Trích xuất dữ liệu văn bản trực tiếp từ file PDF.
  - Xem **Phụ lục - Loại dữ liệu văn bản thuần**.
- **Ảnh chụp Hán Nôm, Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Cấu trúc dữ liệu nộp không có thư mục `vi`.
  - Trích xuất dữ liệu văn bản trực tiếp từ file PDF.
  - Xem **Quy định chung về dữ liệu nộp**.

Quy định về việc đánh bounding box - Loại tài liệu đánh máy (file PDF)

- **Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Không có hình ảnh nên không đánh bounding box.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Chỉ đánh bounding box cho hình ảnh trong thư mục `ch`.
  - Xem **Quy định chung về việc đánh bounding box**.

> **Lưu ý**
>
> Văn bản Hán Nôm phải được tách ra để khớp với dữ liệu bounding box.

Cấu trúc file dóng hàng (align) - Loại tài liệu đánh máy (file PDF)

- **Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Phụ lục - Loại dữ liệu văn bản thuần**.
- **Ảnh chụp Hán Nôm, Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Quy định chung về việc dóng hàng**.