Hướng dẫn xây dựng dữ liệu song song Hán Nôm và Quốc ngữ

Thông tin phiên bản

Phiên bản	Ngày cập nhật	Thông tin
v1	28/10/2026	Phiên bản đầu tiên.
v1.1	30/10/2026	Cập nhật quy định về hình ảnh. Thêm phụ lục quy định cho các loại dữ liệu đặc biệt. Thêm thông tin phiên bản.
v1.2	03/11/2026	Cập nhật thông tin file hướng dẫn sử dụng API Kim Hán Nôm (phiên bản 2026-11-03). Bổ sung hướng dẫn dùng API ở bước chạy OCR và làm sạch dữ liệu. Cập nhật hướng dẫn chung về việc xử lý các hình ảnh bị mờ, bị lem không nhìn thấy chữ.
v1.3	04/11/2026	Bổ sung cột `text_diff` cho các file dóng hàng. Cập nhật hướng dẫn chung về việc thể hiện tình trạng dóng hàng.
v2	05/11/2026	Thay đổi tên các trường trong file dóng hàng. Cập nhật hướng dẫn chung về việc xử lý các hình ảnh thiếu do bản scan lỗi. Bổ sung file ánh xạ hình ảnh `<Tên sách>_image_map.json` (ánh xạ trang Nôm – Quốc ngữ và ghi nhận các trang bị mất khi scan). Cập nhật cấu trúc dữ liệu nộp. Cập nhật thứ tự đọc bản chụp 2 trang, giá trị `null` của `text_diff`, cách tính độ tương đồng.
v2.1	06/11/2026	Cập nhật bảng thuật ngữ. Cập nhật hướng dẫn để xử lý các trường hợp đặc biệt.

Tổng quan

- Tài liệu để phổ biến và hướng dẫn chung các nhóm về quy định xây dựng dữ liệu song song Hán Nôm và Quốc ngữ.
- Áp dụng cho loại sách/tài liệu Hán Nôm **đã có bản dịch Quốc ngữ**; phiên bản chụp trắng đen (bản scan), chụp màu; định dạng PDF.
- Đối với các loại sách/tài liệu hoặc phiên bản khác, xem **Phụ lục**.

Thuật ngữ

Thuật ngữ	Nghĩa dùng trong tài liệu
Trang PDF	Thứ tự của trang trong file PDF, dùng để đánh số tên hình ảnh (Xem **Quy định chung về file hình ảnh**).
Số trang in	Số in sẵn trên trang sách (số Ả Rập hoặc số Hán Nôm), dùng để phát hiện trang bị mất khi scan.
Hình ảnh	Một file `.jpg`. Bản chụp 2 trang là một hình ảnh và được tính là một trang.
`ch`	Hán Nôm: tên thư mục và tên cột dành cho văn bản hoặc hình ảnh Hán Nôm.
`vi`	Quốc ngữ: tên thư mục và tên cột dành cho văn bản hoặc hình ảnh Quốc ngữ.
Bản dịch âm	Bản dịch 1-1: mỗi chữ Hán Nôm ứng với một âm tiết Quốc ngữ (có ngoại lệ như tên riêng, năm). Chỉ bản dịch âm mới được tô màu và ghi `text_diff`.
Bản dịch nghĩa	Bản dịch diễn giải nghĩa, không sát từng chữ. Không tô màu; cột `text_diff` ghi `null`.
Dóng hàng	Ghép câu Nôm với câu Quốc ngữ tương ứng; mỗi hàng của file `.csv`/`.xlsx` là một cặp.
Trang bị mất do scan	Trang có trong sách gốc nhưng không có trong bản scan. Khác với trang mà chính bản Nôm gốc thu thập được đã thiếu (không xử lý).
`[MASK]`	Một chữ Nôm không nhìn thấy được và không có bản dịch âm để đối chiếu.

Quy định chung

- **Trao đổi trực tiếp trên group Zalo** nếu có câu hỏi.
- Liên hệ với người giao tài liệu nếu sách có nhiều trang có chất lượng chưa tốt (rách, mờ,...) với số lượng $>$20% tổng số trang Nôm.
- Luôn làm (dóng hàng) các trang có bản dịch Quốc ngữ, ví dụ các trang bìa Hán Nôm, hoặc mục lục nếu có bản dịch Quốc ngữ thì vẫn làm.
- Luôn làm toàn bộ file sách/tài liệu được giao, ngoại trừ các nhóm được bàn giao sách/tài liệu theo phần hoặc chương (khi đó chỉ nộp các trang được giao, đánh số trang như quy định, `image_map` và file dóng hàng chỉ gồm các trang đó).
- Toàn bộ quy trình (pipeline) **khuyến khích làm tự động**, hạn chế làm thủ công, trừ khi các lỗi cần phải sửa tay thủ công.
- Không giới hạn ngôn ngữ lập trình, nhưng ưu tiên Python.
- Không giới hạn mô hình LLM, OCR, công cụ miễn phí hay tính phí,...
- Nếu nhóm đề xuất tự xây dựng mô hình riêng, cần phải cân nhắc thời gian thực hiện để kịp tiến độ.
- **Dữ liệu có thể sẽ được yêu cầu kiểm tra lại nếu chưa đúng yêu cầu hoặc chất lượng chưa tốt**.
- **Yêu cầu độ tương đồng của sách phải đạt tối thiểu là 95% ($\geq$95%)** (Xem **Đánh giá dữ liệu**), đây chỉ là mức tiêu chuẩn, tiêu chí đánh giá có thể thay đổi để phù hợp với tính chất và tình trạng của sách được giao.
- **Nếu nhóm không thể hoàn thành đúng tiến độ, cần thông báo với các thầy càng sớm càng tốt**.
- Nếu dự án có đính kèm dữ liệu khác có kích thước lớn mà không thể nộp trực tiếp được, có thể lưu trên nền tảng đám mây (**ưu tiên Huggingface**), sau đó liên hệ với các thầy và người bàn giao tài liệu để chia sẻ quyền truy cập vào dữ liệu.

Dữ liệu thô và công cụ hỗ trợ

- Các nhóm sẽ được gửi dữ liệu thô là file sách PDF, các sách này sẽ có bản Nôm và bản dịch Quốc ngữ, thường là bản dịch âm 1-1.
- Dữ liệu từ điển để hỗ trợ kiểm tra chính tả, hoặc các nhóm có thể tự xây dựng riêng (local hoặc query trực tiếp).
- File hướng dẫn sử dụng API của trang web `https://kimhannom.fit.hcmus.edu.vn/`.

Quy trình thực hiện tổng thể

1. Nhận đề tài và xác nhận phạm vi

Trước khi làm, nhóm phải xác nhận:

- Mã đề tài và tên tác phẩm.
- Quyển, tập, chương hoặc khoảng trang được giao.
- Nguồn Nôm và nguồn Quốc ngữ.
- Định dạng từng nguồn: ảnh, PDF Scan, PDF Text hoặc Text.

> **Lưu ý**
>
> Không bắt đầu OCR hàng loạt nếu chưa chắc hai bản chứa cùng phạm vi nội dung.

> **Lưu ý**
>
> Luôn làm (dóng hàng) các trang có bản dịch Quốc ngữ, ví dụ các trang bìa Hán Nôm, hoặc mục lục nếu có bản dịch Quốc ngữ thì vẫn làm (Xem **Quy định chung**).

2. Kiểm tra nguồn dữ liệu

- Kiểm tra xem chất lượng file sách, nếu có rách, mờ hoặc chất lượng không tốt cần liên hệ người giao tài liệu trước khi thực hiện (Xem **Quy định chung**).

3. Phân loại hình ảnh

- Chia file PDF thành các hình ảnh, đặt tên theo đúng cú pháp (Xem **Quy định chung về file hình ảnh**) (có thể sử dụng pdfslice-py).
- Phân loại hình ảnh vào các thư mục (Xem **Quy định chung về dữ liệu nộp**).
- Tiền xử lý:
  - Kiểm tra hướng của hình ảnh, nếu sai thì phải xoay lại hình ảnh (có thể sử dụng pdfarranger).
  - Tăng chỉnh độ sáng, làm nét hình ảnh,...nếu cần thiết.
- Nếu nhóm có tiền xử lý hình ảnh, theo **Quy định chung về file hình ảnh** thì nhóm phải merge các hình ảnh thành file PDF mới (`<Tên sách>_updated.pdf`) và báo cáo.
- Ghi nhận các trang bị mất do scan (nếu có) và xử lý theo **Quy định chung về file hình ảnh**.

4. Chạy OCR hình ảnh

- Cài đặt các mô hình để chạy OCR theo từng ngôn ngữ Nôm hoặc Quốc ngữ.
  - Nôm:
    - Ưu tiên sử dụng công cụ `https://kimhannom.fit.hcmus.edu.vn/` để chạy OCR chữ Nôm, vì đây là công cụ được tinh chỉnh cho dữ liệu Hán Nôm.
    - Khi gọi trực tiếp qua API (xem file hướng dẫn sử dụng API):
      - Quy trình: `image-upload` → `structure-classification` (đặt `ocr_id`, `lang_type`, `reading_direction` bằng 0 để server tự nhận diện) → `image-ocr`.
      - Giới hạn trên website: 25 lượt/phút, 50 lượt/giờ, 200 lượt/ngày, 600 lượt/tuần. Mỗi ảnh cần ít nhất 2 lượt gọi, nên cần lập kế hoạch cho sách nhiều trang và đặt thời gian trễ giữa các request.
      - Nếu bounding box từ `image-ocr` không hợp lệ: chỉnh lại box, cắt từng dòng rồi dùng `image-rec`.

    - Có thể dùng các mô hình OCR chữ Hán, hoặc các mô hình OCR đa năng (Xem **Mô hình OCR chữ Nôm**).
    - Hoặc nhóm tự xây dựng mô hình OCR chữ Nôm riêng (cần cân nhắc thời gian thực hiện để kịp tiến độ).
  - Quốc ngữ:
    - Có thể dùng các mô hình OCR chữ Quốc ngữ, hoặc các mô hình OCR đa năng (Xem **Mô hình OCR chữ Quốc ngữ**).
    - Hoặc nhóm tự xây dựng mô hình OCR chữ Quốc ngữ riêng (cần cân nhắc thời gian thực hiện để kịp tiến độ).
- Nên chạy kiểm thử mô hình với vài hình ảnh mẫu (sample) để kiểm tra kết quả.
- Có thể chạy 2–3 mô hình OCR, sau đó sử dụng các kỹ thuật voting để đạt kết quả tốt hơn.

5. Làm sạch dữ liệu

- Map dữ liệu OCR theo định dạng của PPOCRLabel (Xem **Quy định chung về file OCR**).
  - Với kết quả `image-ocr` (`ocr_id` khác 3), trường `details.details` đã có `transcription`, `points` (đúng 4 điểm) và `difficult`, cùng cấu trúc với phần tử trong `Label.txt`. `difficult` là trường do công cụ OCR Hán Nôm sinh ra, được giữ lại mà không cần chú thích (các trường thêm khác, nếu có, phải có chú thích). Với `ocr_id` = 3 không có trường này.
  - Văn bản `transcription` từ API vẫn phải được làm sạch theo quy định.
- Kiểm tra bounding box, loại bỏ các bounding box không cần thiết (Xem **Quy định chung về việc đánh bounding box**).
- Làm sạch dữ liệu văn bản (Xem **Quy định chung về dữ liệu văn bản**).
- Kiểm tra lỗi chính tả, sửa lỗi nếu cần thiết (không sửa từ cổ và cách viết có trong bản gốc):
  - Có thể dùng từ điển (Xem **Nguồn từ điển**).
  - Hoặc các công cụ kiểm tra chính tả (Xem **Mô hình kiểm tra chính tả (Spellcheck)**).

6. Dóng hàng dữ liệu

- Ghép từ/câu bị ngắt do chuyển trang trước khi thực hiện việc tách câu.
- Xây dựng mô hình để dóng hàng dữ liệu (Xem **Mô hình dóng hàng Nôm – Quốc ngữ**).
- Dóng hàng dữ liệu theo định dạng file `<Tên sách>.csv` và `<Tên sách>.xlsx` (Xem **Quy định chung về việc dóng hàng**).
- Nếu sách có cả hai thư mục `ch` và `vi`, có thể tạo thêm file ánh xạ hình ảnh `<Tên sách>_image_map.json` (Xem **Quy định chung về file ánh xạ hình ảnh**).

7. Đánh giá dữ liệu

- Kiểm tra độ tương đồng giữa chữ Nôm và chữ Quốc ngữ (Xem **Đánh giá dữ liệu**).

8. Nộp dữ liệu

- Kiểm tra dữ liệu trước khi nộp, đảm bảo các file đúng định dạng, không bị lỗi font, không bị lệch cột, không bị trùng lặp hình ảnh,...:
  - Hình ảnh: tên đúng cú pháp, đúng hướng, không trùng lặp (Xem **Quy định chung về file hình ảnh**).
  - `Label.txt`, `fileState.txt`: mở được bằng PPOCRLabel, mỗi box đúng 4 điểm, mọi dòng của `fileState.txt` là `1` (Xem **Quy định chung về file OCR**).

  - File đóng hàng: `.csv` và `.xlsx` mở được bình thường bằng Excel hoặc Google Sheets; `text_diff` là JSON hợp lệ, `pos` khớp với chuỗi trong ô và khớp với màu trong `.xlsx` (Xem **Cột `text_diff`**).
  - `image_map` (nếu nộp): Xem **Quy định chung về file ánh xạ hình ảnh**.
  - Báo cáo và mã nguồn: Xem **Quy định chung về file báo cáo** và **Quy định chung về mã nguồn**.
- Nộp dữ liệu theo đúng cấu trúc (Xem **Quy định chung về dữ liệu nộp**).

Quy định chung về dữ liệu nộp

```
<MSSV1_MSSV2_MSSV3_MSSV4>.zip/
|-- <Tên sách>/
|   |-- ch/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label_char.txt (nếu có)
|   |   |-- fileState_char.txt (nếu có)
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- vi/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- intro/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- ref/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- toc/
|   |   |-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   |-- Label.txt
|   |   `-- fileState.txt
|   |-- blank/
|   |   `-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |-- misc/
|   |   `-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |-- missing/
|   |   |-- ch/
|   |   |   `-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |   `-- vi/
|   |       `-- <Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg
|   |-- <Tên sách>.pdf
|   |-- <Tên sách>_updated.pdf (nếu có)
|   |-- <Tên sách>_image_map.json (ánh xạ hình ảnh ch - vi, nếu có)
|   |-- <Tên sách>.xlsx (dữ liệu đã dóng hàng)
|   `-- <Tên sách>.csv (dữ liệu đã dóng hàng)
|-- <MSSV1_MSSV2_MSSV3_MSSV4>_report.pdf (dựa theo tên file zip)
|-- source.zip
`-- extras.zip (dữ liệu thêm,...)
```

Chú thích

- **Tên file zip**: Do các thầy phổ biến. Mặc định: `MSSV1_MSSV2_MSSV3_MSSV4.zip`.
- Thư mục `<Tên sách>`: Thư mục chứa dữ liệu của sách
  - **Tên sách phải giữ theo tên file sách PDF được giao**, trừ khi có sự cập nhật từ phía người bàn giao.
  - Với tài liệu do nhóm tự soạn (các loại `Tnom`, `Tnomw`, `T1`, `T1w`, xem **Phụ lục - Chú thích về phân loại sách**), `<Tên sách>` có dạng `<loại>_<tên>` theo quy ước đặt tên do người bàn giao quy định, và

khi đó tên file PDF do nhóm ghép được xem là `<Tên sách>.pdf`.
  - Ví dụ trong quá trình xử lý tên sách `Lorem ipsum` được chuyển thành `Lorem%20ipsum`, thì dữ liệu nộp phải chuyển lại `Lorem ipsum` y như tên sách được giao.
  - **Quy định này áp dụng cho toàn bộ dữ liệu nộp**.
- Thư mục `vi` (**bắt buộc có**, trừ các loại dữ liệu nêu ở **Phụ lục**): Thư mục chứa các trang Quốc ngữ
  - Tên hình ảnh `<Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg`.
  - File dữ liệu OCR `Label.txt`, theo format của PPOCRLabel (Xem **Quy định chung về file OCR**).
  - File tiến trình đánh nhãn `fileState.txt`, theo format của PPOCRLabel (Xem **Quy định chung về file OCR**).
- Thư mục `ch` (**bắt buộc có**, trừ các loại dữ liệu nêu ở **Phụ lục**): Thư mục chứa các trang Hán Nôm
  - Cấu trúc giống như thư mục `vi`.
  - File dữ liệu OCR theo từng chữ `Label_char.txt` (nếu có), theo format của PPOCRLabel (Xem **Quy định chung về file OCR**).
  - File tiến trình đánh nhãn theo từng chữ `fileState_char.txt` (nếu có), theo format của PPOCR-Label (Xem **Quy định chung về file OCR**).
- Thư mục `intro` (không bắt buộc làm): Thư mục chứa các trang giới thiệu, nếu có
  - Cấu trúc giống như thư mục `vi`; nếu nộp thư mục này thì phải có đủ `Label.txt` và `fileState.txt`.
- Thư mục `ref` (không bắt buộc làm): Thư mục chứa các trang chú thích, nếu có
  - Cấu trúc giống như thư mục `vi`; nếu nộp thư mục này thì phải có đủ `Label.txt` và `fileState.txt`.
- Thư mục `toc` (không bắt buộc làm): Thư mục chứa các trang mục lục, nếu có
  - Cấu trúc giống như thư mục `vi`; nếu nộp thư mục này thì phải có đủ `Label.txt` và `fileState.txt`.
- Thư mục `blank`: Thư mục chỉ chứa các trang trắng, các trang không có dữ liệu cần OCR (ví dụ: trang có khung khắc in Nôm nhưng không có chữ nào), nếu có.
- Thư mục `misc`: Thư mục chứa các trang còn lại, thường là trang bìa hoặc không liên quan.
- Thư mục `missing`: Thư mục chứa các trang Quốc ngữ hoặc trang Nôm bị mất do bị scan thiếu
  - Nếu bản dịch âm Quốc ngữ cho trang Nôm bị mất do scan lỗi, trang Nôm sẽ lưu trong cả hai thư mục `ch` và `missing/ch`.
  - Nếu trang Nôm cho bản dịch âm Quốc ngữ bị mất do scan lỗi, trang Quốc ngữ sẽ loại bỏ khỏi thư mục `vi` và chỉ lưu ở `missing/vi`, không OCR (trừ khi có yêu cầu cụ thể xử lý trang này, khi đó đưa lại vào thư mục `vi`).
  - Thư mục `missing` sẽ không có file dữ liệu OCR `Label.txt` và file tiến trình đánh nhãn `fileState.txt`.
  - Xem **Quy định chung về file hình ảnh**.
- File `<Tên sách>.pdf` (**bắt buộc có**): **File tài liệu gốc** mà nhóm được bàn giao (hoặc file PDF do nhóm tự soạn, xem tên sách ở trên).
- File `<Tên sách>_updated.pdf`: File tài liệu mà nhóm đã chỉnh sửa (nếu có).
- File `<Tên sách>_image_map.json` (không bắt buộc): Xem **Quy định chung về file ánh xạ hình ảnh**.
- File `<Tên sách>.xlsx` (**bắt buộc có**): Xem **Quy định chung về việc dóng hàng**.
- File `<Tên sách>.csv` (**bắt buộc có**): Xem **Quy định chung về việc dóng hàng**.
- File `<MSSV1_MSSV2_MSSV3_MSSV4>_report.pdf` (**bắt buộc có**): Xem **Quy định chung về file báo cáo**.
- File `source.zip` (**bắt buộc có**): Xem **Quy định chung về mã nguồn**.
- File `extras.zip`: Dữ liệu thêm. Không có quy định cụ thể, nhưng cần nêu rõ trong báo cáo.

Quy định chung về file hình ảnh

- Cú pháp: `<Tên sách>.<Số thứ tự trang>[_<Số thứ tự hình ảnh>].jpg`.
- `<Số thứ tự trang>`:
  - Gồm ít nhất 3 số, **với số thứ tự đánh từ số 1, tính từ trang đầu tiên của file `<Tên sách>_updated.pdf` nếu có, nếu không thì của file PDF gốc**. Ví dụ `Lorem ipsum.001.jpg`, `Lorem ipsum.011.jpg`, `Lorem ipsum.111.jpg`.
  - Bản chụp 2 trang (một hình ảnh chứa hai trang sách) được xem như một trang: một hình ảnh, một số thứ tự trang.
  - Nếu số trang của sách lớn hơn 999 thì để không thêm chữ số 0 ở đầu nữa, ví dụ `Lorem ipsum.1234.jpg`, `Lorem ipsum.123456.jpg`,...
- `[_<Số thứ tự hình ảnh>]`:
  - Chỉ thêm số thứ tự hình ảnh khi có nhiều hơn 1 ảnh chụp Hán Nôm hoặc Quốc ngữ trong trang (ảnh Quốc ngữ đọc như bình thường: từ trái sang phải, từ trên xuống dưới).
  - Đánh dấu số thứ tự hình ảnh: từ trái sang phải, từ trên xuống dưới. Khi các hình ảnh trong cùng một trang liên quan với nhau hoặc ảnh hưởng đến thứ tự đọc, số thứ tự hình ảnh cũng là thứ tự đọc của chúng.
  - Gồm ít nhất 1 số, **với số thứ tự đánh từ số 1, tính từ hình đầu tiên trong trang**. Ví dụ `Lorem ipsum.001_1.jpg`, `Lorem ipsum.001_10.jpg`, `Lorem ipsum.001_100.jpg`.
- Định dạng hình ảnh (extension): `.jpg` (JPEG). Không sử dụng định dạng hình ảnh khác.
- Toàn bộ hình ảnh (kể cả trang trắng, trang bìa,...) phải được kiểm tra và chỉnh sửa nếu bị sai hướng. Có thể dựa vào số trang, chữ viết hoặc gáy sách để xác định hướng của hình ảnh.
- Một hình ảnh có thể thuộc 1 hoặc nhiều thư mục khác nhau, ví dụ 1 hình ảnh đều thuộc thư mục `ch` hoặc `vi` (trường hợp hình ảnh có Nôm và Quốc ngữ lẫn lộn, xem ở dưới), nhưng khi merge lại file PDF phải **đảm bảo là không có hình ảnh trùng lặp**. File PDF mới gồm hình ảnh của tất cả các thư mục (kể cả `missing/vi`); hình ảnh nằm đồng thời trong `ch` và `missing/ch` chỉ đưa vào một lần.
- Đối với hình ảnh scan bị lỗi, trang sách bị chia đôi thành 2 hình ảnh thì phải ghép hình ảnh lại theo đúng chiều và cập nhật sách.
- **Hình ảnh được chia từ file PDF phải có độ phân giải càng cao càng tốt**. Ví dụ ảnh gốc ở file PDF có độ phân giải 3144 x 2096 thì khi chiết ra vẫn giữ độ phân giải 3144 x 2096.
- Nếu nhóm có bất kỳ thay đổi gì về hình ảnh, như chỉnh độ sáng, xoay trang, làm nét ảnh,...**cần phải merge thành file PDF mới**, gửi cùng với file thư mục (Xem **Quy định chung về dữ liệu nộp**) và **thông báo với người giao sách là có thay đổi về nội dung file PDF**.
- Các trường hợp đặc biệt do bản scan bị lỗi:
  - Dựa vào số trang in sẵn trên trang (dễ nhận biết hơn) để đánh giá trang bị mất trong quá trình scan tài liệu; với bản chụp 2 trang, đối chiếu số trang của cả hai trang trong ảnh.
  - Trường hợp có sự thay đổi thất thường về thứ tự trang trong tài liệu (khó nhận biết hơn) (dịch giả có thể ghi chú), nếu sách không có đánh số trang, suy ra là tài liệu gốc bị mất trang Nôm từ đó cũng không có bản dịch. Không xử lý gì thêm. Tương tự, nếu bản Nôm gốc thu thập được đã thiếu trang thì bản dịch Quốc ngữ cũng thiếu (thường được dịch giả ghi chú): không xử lý gì thêm.
  - Nếu có bản dịch Quốc ngữ nhưng bản Nôm bị mất trong quá trình scan:
    - Loại bỏ hình ảnh bản dịch Quốc ngữ khỏi thư mục `vi` và lưu hình ảnh trong thư mục `missing/vi`. Không OCR hình ảnh này và không đưa vào file dóng hàng.
    - Nếu có yêu cầu cụ thể phải xử lý trang này (OCR, dịch ngược từ bản dịch âm Quốc ngữ sang Nôm): đưa hình ảnh ra khỏi thư mục `missing/vi` và lưu lại trong thư mục `vi`, xử lý như trang bình thường.
    - Hạn chế dịch ngược từ âm Quốc ngữ sang Nôm mà nên tìm bản Nôm gốc hoặc yêu cầu bản scan lại để bổ sung (Xem **Quy định chung về việc dóng hàng**).

  - Nếu có bản Nôm nhưng bản dịch bị mất trong quá trình scan:
    - Lưu hình ảnh bản Nôm trong cả hai thư mục `ch` và `missing/ch`.
    - Vẫn chạy OCR như thường để ra văn bản Nôm.
    - Có thể dựa vào từ điển hoặc các bản dịch đã có để tổng hợp bản dịch âm (có thể áp dụng phương pháp dịch máy dựa trên ví dụ - EBMT).
    - Khi dóng hàng thì phải tô toàn nội dung bản Nôm và bản dịch Quốc ngữ (dự đoán) màu vàng, bởi vì đây là dữ liệu dự đoán (Xem **Quy định chung về việc dóng hàng**).
  - Mọi trường hợp trang bị mất trong quá trình scan (kể cả các ảnh trong `missing/ch`, `missing/vi`) nên được ghi nhận trong file ánh xạ hình ảnh (nếu nhóm nộp file này) (Xem **Quy định chung về file ánh xạ hình ảnh**).

> **Lưu ý**
>
> Công cụ PPOCRLabel không được tối ưu cho hình ảnh có độ phân giải cao, nên có thể rescale về 1K để đánh dấu, sau đó căn cứ vào scale để upscale bbox lại về với độ phân giải ban đầu.

Quy định chung về file ánh xạ hình ảnh

- Mục đích: ghi nhận trang Nôm nào tương ứng với trang Quốc ngữ nào (nhất là khi hai bản không theo thứ tự 1-1, ví dụ phân loại T1), và ghi nhận các trang bị mất trong quá trình scan (để cập nhật bản scan sau).
- File này **không bắt buộc**. Phạm vi áp dụng: sách có **cả hai** thư mục `ch` và `vi` (hình ảnh Nôm và hình ảnh Quốc ngữ). Không áp dụng cho dữ liệu văn bản thuần hoặc sách chỉ có một loại hình ảnh. Các thư mục `intro`, `ref`, `toc` (thường là trang Quốc ngữ), `blank` và `misc` không đưa vào file này.
- Tên file: `<Tên sách>_image_map.json`, đặt trong thư mục `<Tên sách>` (Xem **Quy định chung về dữ liệu nộp**).
- Giá trị của file là **một chuỗi JSON hợp lệ** (mã hoá UTF-8), gồm các trường sau:

Trường	Kiểu	Chú thích
`pairs`	mảng đối tượng	Danh sách các cặp ánh xạ.
`ch`	mảng chuỗi	Tên các hình ảnh Nôm của cặp, theo thứ tự đọc (với phần Nôm đọc ngược của loại T1 là số trang giảm dần), không chứa tên thư mục. Mảng rỗng `[]` nếu không có hình ảnh Nôm tương ứng.
`vi`	mảng chuỗi	Tên các hình ảnh Quốc ngữ của cặp, quy ước như `ch`.
`note`	chuỗi	Không bắt buộc. Ghi chú tự do.

- Quy ước:
  - Tên hình ảnh giống `img_id` trong file dóng hàng, không chứa tên thư mục.
  - Một cặp có thể gồm 1 hoặc nhiều hình ảnh mỗi vế, ví dụ 1 trang Quốc ngữ là bản dịch của 2 trang Nôm.
  - Các cặp trong `pairs` sắp xếp theo thứ tự đọc của sách (theo bản Quốc ngữ; cặp không có hình ảnh Quốc ngữ đặt theo vị trí của trang Nôm).
  - **Hai vế không được cùng rỗng.** Cặp có một vế rỗng nghĩa là trang bị mất trong quá trình scan, cần cập nhật bản scan sau.

  - Mỗi tên hình ảnh chỉ xuất hiện **tối đa một lần** trong mỗi vế (`ch` hoặc `vi`) của toàn bộ file. Hình ảnh có cả Nôm và Quốc ngữ (T2b) nằm ở cả hai thư mục thì xuất hiện một lần trong `ch` và một lần trong `vi`.
  - Trang mà cả bản Nôm lẫn bản dịch đều bị mất, hoặc bản Nôm gốc thu thập được đã thiếu trang (không có dữ liệu gốc): **không ghi vào file**, không xử lý gì thêm (Xem **Quy định chung về file hình ảnh**).
- Ví dụ:

```
{
  "pairs": [
    { "ch": ["Lorem ipsum.010.jpg"], "vi": ["Lorem ipsum.001.jpg"] },
    { "ch": ["Lorem ipsum.009.jpg"], "vi": ["Lorem ipsum.002.jpg"] },
    { "ch": ["Lorem ipsum.008.jpg", "Lorem ipsum.007.jpg"], "vi": ["Lorem ipsum.003.jpg"] },
    { "ch": ["Lorem ipsum.020.jpg"], "vi": [],
      "note": "Trang Quốc ngữ tương ứng bị mất khi scan" },
    { "ch": [], "vi": ["Lorem ipsum.031.jpg"],
      "note": "Trang Nôm tương ứng bị mất khi scan" }
  ]
}
```

- Hai cặp có một vế rỗng ở trên cho thấy quan hệ với các thư mục `missing`:
  - Hình ảnh nằm trong `missing/ch` ⇔ nằm trong cặp có `vi` rỗng.
  - Hình ảnh nằm trong `missing/vi` ⇒ nằm trong cặp có `ch` rỗng. Chiều ngược lại không bắt buộc: trang đã được đưa lại vào `vi` theo yêu cầu thì không còn nằm trong `missing/vi`.

> **Lưu ý**
>
> Nếu nộp file này, nên kiểm tra tự động trước khi nộp: file là JSON hợp lệ; mọi tên hình ảnh ở vế `ch` đều tồn tại trong `ch` hoặc `missing/ch`, mọi tên ở vế `vi` đều tồn tại trong `vi` hoặc `missing/vi`; không có tên trùng trong cùng một vế; không có cặp nào có hai vế rỗng; các thư mục `missing` khớp với các cặp có một vế rỗng.

Quy định chung về file OCR

- Với thư mục `vi` và `ch`, sẽ bao gồm chủ yếu hai file `Label.txt` và `fileState.txt` theo định dạng của PPOCRLabel:
  - **`Label.txt`**: File dữ liệu gồm toạ độ bounding box và văn bản đã nhận diện, mỗi hàng (`\n`) là dữ liệu bounding box cho một hình ảnh:
    - Phần đầu là đường dẫn hình ảnh (image path): cú pháp `<folderName>/<imageName>`. Ví dụ với hình ảnh `a.jpg` nằm trong thư mục `foo`, khi dùng công cụ PPOCRLabel để mở thư mục `foo` thì file `Label.txt` sẽ được lưu tại `foo/Label.txt` và đường dẫn hình ảnh trong `Label.txt` sẽ có cú pháp `foo/a.jpg`.
    - Phần sau là dữ liệu bounding box: mảng chứa các đối tượng (array object) với yêu cầu có 2 trường chính là `transcription` (văn bản nhận dạng) và `points` (toạ độ các điểm của bounding box).
    - **Mỗi box chỉ có đúng 4 điểm**, không được ít hơn hoặc nhiều hơn.
    - Toạ độ trong `points` tính trên đúng hình ảnh được nộp trong thư mục; nếu hình ảnh bị thay đổi (xoay, ghép, đổi kích thước) sau khi đánh nhãn thì phải quy đổi lại toạ độ.
    - Hai phần được cách nhau bởi ký tự `\t` (tab).
    - **Nội dung `transcription` phải được làm sạch** và tuân thủ theo **Quy định chung về dữ liệu văn bản**.

> **Lưu ý**
>
> Ngoài hai trường chính là `transcription` và `points`, có thể thêm trường khác (như confident, score,...) nhưng phải có chú thích rõ. Riêng trường `difficult` do công cụ OCR Hán Nôm sinh ra thì không cần chú thích.

- **`fileState.txt`**: File tiến trình đánh nhãn, mỗi hàng (`\n`) là tình trạng đánh nhãn cho một hình ảnh:
  - Phần đầu là đường dẫn hình ảnh (image path) có cú pháp giống như trong file `Label.txt`
  - Phần sau là tình trạng gán nhãn, `1` là đã hoàn thành, `0` là chưa hoàn thành.
  - Hai phần được cách nhau bởi ký tự `\t` (tab).
- **`Label_char.txt`** (nếu có): File dữ liệu gồm toạ độ bounding box cho từng chữ Hán Nôm (mỗi box là một chữ, khác với `Label.txt` là cả cột), dùng cho các trường hợp cần box riêng cho từng chữ.
- **`fileState_char.txt`** (nếu có): File tiến trình đánh nhãn cho từng chữ Hán Nôm.

`Label.txt` — mỗi ảnh là **một dòng** trong file; TAB là ký tự tab (`\t`), LF là ký tự xuống dòng (`\n`). Việc ngắt dòng bên dưới chỉ do khổ giấy, không có trong file thật.

```
vi/Lorem ipsum.024.jpgTAB[{"transcription":"Lorem
     ipsum","points":[[249,361],[1064,361],[1064,465],[249,465]]},{"transcription":"Lorem
     ipsum","points":[[254,540],[1068,540],[1068,878],[254,878]]}]LF
vi/Lorem ipsum.025.jpgTAB[{"transcription":"Lorem
     ipsum","points":[[249,361],[1064,361],[1064,465],[249,465]]},{"transcription":"Lorem
     ipsum","points":[[254,540],[1068,540],[1068,878],[254,878]]}]LF
```

Cùng một dòng của ảnh `vi/Lorem ipsum.024.jpg`, trình bày lại cho dễ đọc (*chỉ để minh hoạ*, trong file thật phải nằm trên một dòng):

```
vi/Lorem ipsum.024.jpg          <- (1) đường dẫn ảnh: <folderName>/<imageName>
TAB                             <- (2) ký tự tab ngăn cách
[                               <- (3) mảng JSON, mỗi phần tử là một bounding box
  { "transcription": "Lorem ipsum",
    "points": [[249,361], [1064,361], [1064,465], [249,465]] },   <- đúng 4 điểm
  { "transcription": "Lorem ipsum",
    "points": [[254,540], [1068,540], [1068,878], [254,878]] }
]LF
```

`fileState.txt` — sau tab là `1` (đã hoàn thành) hoặc `0` (chưa hoàn thành):

```
vi/Lorem ipsum.024.jpgTAB1LF
vi/Lorem ipsum.025.jpgTAB1LF
```

Quy định chung về việc đánh bounding box

- Các bounding box phải ôm sát, tránh để bị lệch các hàng, chữ.
- Bỏ qua tranh/ảnh nếu có. Bảng biểu là trường hợp đặc biệt: vẫn OCR văn bản trong bảng.
- Loại bỏ các dữ liệu không cần thiết trong trang như: số trang (cả số trang Nôm và Quốc ngữ), tiêu đề (thường là tên sách ở đầu trang), tên sách (cả Nôm và Quốc ngữ), chân trang, dấu thư viện/dấu sở hữu và ghi chú ngoài khung,...Tiêu đề chương/mục thuộc nội dung chính và có bản dịch thì **giữ lại**.
- Trang Nôm (**ưu tiên**):
  - Cấp độ: Đánh **theo từng cột dọc**. Nếu chữ Nôm được viết ngang thì đánh theo hàng.
  - Đối với các hàng chữ Nôm được cách ra (có khoảng trắng giữa các chữ trong cột) thì đánh 1 box riêng, không gộp chung.
  - Đối với các chữ Nôm được ghép từ 2 ký tự hàng ngang, đánh 2 box riêng biệt (thường thấy ở các bản Nôm viết tay).

  - Đối với chú thích chữ nhỏ viết thành hai hàng (hai cột nhỏ) trong một cột chính, đánh 2 box riêng biệt cho hai cột nhỏ, theo thứ tự đọc từ phải sang trái.
- Trang Quốc ngữ:
  - Cấp độ: Nếu công cụ có hỗ trợ thì đánh box **theo hàng** (cột ngang) hoặc **theo đoạn**, còn không thì đánh 1 box cho **toàn trang**.
- Thứ tự bounding box:
  - Nôm: từ phải sang trái, từ trên xuống dưới. Nếu chữ Nôm được viết ngang thì từ trái sang phải, từ trên xuống dưới
  - Quốc ngữ: từ trái sang phải, từ trên xuống dưới.
- Nếu có dữ liệu bounding box cho từng chữ Nôm, lưu thành hai file riêng `Label_char.txt` và `fileState_char.txt` (Xem **Quy định chung về file OCR**).
- Nếu trang bị lem hoặc nhoè chữ (không đọc được), vẫn đánh bounding box cho cả cột. Nếu không thể nhìn thấy chữ và không có bản dịch âm để đối chiếu, thì đánh `[MASK]` vào chữ bị khuyết (Xem **Quy định chung về dữ liệu văn bản**).
- Nếu trang bị rách, chỉ đánh bounding box tới ranh giới trang bị rách.
- Nếu trang bị mờ (chữ vẫn đọc được), vẫn đánh bounding box như bình thường.
- Cần lưu ý để phân biệt giữa trang trắng (blank) và trang bị mờ, một số sách có giấy mỏng khi scan sẽ bị hằn trang sau lên, nên đó vẫn là trang trắng chứ không phải bị mờ.
- **Yêu cầu phải đánh nhãn cho toàn bộ hình ảnh có trong thư mục, hoặc theo phần/chương được giao**. Khi nộp, mọi dòng trong `fileState.txt` phải là `1` và mọi hình ảnh trong thư mục phải có dòng trong `Label.txt`.

> **Lưu ý**
>
> Phải đảm bảo các file đúng định dạng của PPOCRLabel, mở và xem được trên công cụ PPOCR-Label.

Các trường hợp đặc biệt

*Xem **Phụ lục - Chú thích về phân loại sách** để biết về các phân loại sách.*

- **Bản chụp 1 trang**:
  - Nôm và Quốc ngữ lẫn lộn (thường là phân loại T2b, T2bw):
    - Lưu hình ảnh cho cả hai thư mục `ch` và `vi`. Hình ảnh trong `ch` thì chỉ giữ lại các bounding box Nôm và ngược lại, hình ảnh trong `vi` chỉ giữ lại các bounding box Quốc ngữ.
    - Thứ tự bounding box vẫn theo như trên, bởi vì đã loại bỏ các bounding box không cùng ngôn ngữ.
- **Bản chụp 2 trang**:
  - Nôm – Nôm (thường là phân loại T1, T1w, Tnom, Tnomw):
    - Thứ tự bounding box: **trang phải đọc trước, trang trái đọc sau** (phần Nôm đọc từ phải sang trái; ở loại T1, phần Nôm được đọc ngược từ cuối sách). Cột đầu tiên bên phải của trang phải tính là 1, đánh thứ tự tiếp theo từ phải sang trái cho trang phải, sau đó là cột đầu tiên bên phải của trang trái.
    - Nếu Nôm viết ngang thì xử lý như trường hợp Quốc ngữ – Quốc ngữ.
  - Quốc ngữ – Quốc ngữ (thường là T1, T1w, Tqn): trang trái đọc trước, trang phải đọc sau. Hàng đầu tiên của trang trái tính là 1, đánh thứ tự tiếp theo từ trên xuống dưới như bình thường cho trang trái, sau đó là hàng đầu tiên của trang phải.
  - Nôm – Quốc ngữ (thường là phân loại T2, T2w): xử lý như bản chụp 1 trang.

Quy định chung về dữ liệu văn bản

- Bỏ các trang không thuộc nội dung chính; đầu trang, chân trang và các dữ liệu không cần thiết khác xem **Quy định chung về việc đánh bounding box**.
- Loại dòng trùng do OCR lặp vùng.
- Loại bỏ chú thích nằm ngoài nội dung chính, bao gồm chú thích ở chân trang, các chỉ mục chú thích chèn trong nội dung chính (như [1], (1) v.v..) và các ghi chú của dịch giả chèn giữa bản dịch Quốc ngữ.
- Sửa ký tự rác và khoảng trắng bất thường.
- Chuẩn hóa dấu câu nhưng không thay đổi nghĩa.
- Giữ tên riêng, niên hiệu, con số và đơn vị đo theo nguồn.
- Nôm:
  - Các chữ viết dính liền, không có khoảng trắng. Sử dụng các dấu phù hợp, ví dụ `、` (dấu phẩy), `。` (dấu chấm),...Không tự thêm dấu câu không có trong bản gốc.
  - Ký tự hợp lệ, có thể xem được bằng các font chữ Hán Nôm được đề cập trong phần thông tin tham khảo.
  - Chữ chưa có trong Unicode hoặc không có trong font nào: ghi bằng ký tự thay thế duy nhất 〓 (U+3013) và liệt kê các trường hợp (vị trí, mô tả cấu tạo chữ) trong báo cáo.
- Quốc ngữ:
  - Giữ nguyên cách viết của bản gốc, kể cả từ cổ và cách đặt dấu thanh cũ (bản dịch của sách Nôm cổ, như sách Công giáo, có thể dùng từ cổ để khớp ngữ cảnh); chỉ sửa lỗi do OCR.
  - Khoảng trắng và dấu câu tuân theo quy cách Tiếng Việt thông thường, ví dụ khoảng trắng sau dấu phẩy, dấu chấm,...
  - Mỗi hàng của file dóng hàng là một câu.
    - Từ bị ngắt bằng dấu gạch ngang ở cuối dòng thì ghép lại, bỏ dấu gạch ngang nếu chỉ do ngắt dòng, ví dụ: `tin-\ntưởng`, ghép lại thành chữ `tin tưởng` và bỏ dấu `-` nếu trong bản dịch âm gốc không có quy định nối chữ bằng dấu `-` (thường là các sách Quốc ngữ cũ).
    - Giữ dấu gạch ngang nếu là tên riêng hoặc được quy định như `A-ve`.
    - Các dòng được nối bằng một khoảng trắng.
    - Không có ký tự xuống dòng trong một ô của file `.csv`/`.xlsx` (cả Nôm và Quốc ngữ).
- Nếu văn bản bị lem, bị nhoè không thể nhìn thấy chữ:
  - Nếu có bản dịch âm cho chữ đó (người dịch vẫn dịch được) thì dùng bản dịch âm để dự đoán chữ Nôm. Các chữ dự đoán phải được tô màu vàng trong file dóng hàng (Xem **Quy định chung về việc dóng hàng**).
  - Nếu không có bản dịch âm để đối chiếu, thì đánh `[MASK]` vào chữ bị khuyết. Mỗi chữ bị khuyết đánh một `[MASK]`; số chữ bị khuyết phải được xác định bằng cách đếm lại trên hình ảnh (ví dụ theo độ dài cột chữ).

Quy định chung về việc dóng hàng

Tách câu

- **Ghép từ/câu bị ngắt do chuyển trang** trước khi thực hiện việc tách câu. Câu được ghép lấy `img_id` của hình ảnh chứa phần đầu câu, và `sentence_id` được đánh số trên hình ảnh đó.
- **Thứ tự đọc**: ghép câu ngắt trang, đánh `sentence_id` và sắp xếp các hàng của file dóng hàng đều theo thứ tự đọc của sách. Với phần Nôm đọc ngược của loại T1, trang kế tiếp có số trang trong tên file nhỏ hơn (giảm dần), và trong bản chụp 2 trang thì trang phải đọc trước trang trái (Xem **Các trường hợp đặc biệt**).
- Nên kiểm tra: văn bản `transcription` trong `Label.txt` (nối theo thứ tự đọc) phải khớp với văn bản trong file dóng hàng, ngoại trừ các câu được ghép do chuyển trang.
- Nôm:
  - Dùng 。!?;： làm gợi ý, không coi là quy tắc tuyệt đối.
  - Văn bản cổ có thể không có dấu câu hoặc dấu câu do người biên tập thêm.
- Quốc ngữ:
  - Dùng .?!;: kết hợp cấu trúc ngữ nghĩa.
  - Chú ý chữ viết tắt, số thứ tự và tên riêng có dấu chấm.
  - Bản dịch có thể gộp hoặc diễn giải nhiều câu Nôm.

Cấu trúc file dóng hàng (align)

- Cấu trúc file `<Tên sách>.csv`:

Tên cột	Chú thích
`img_id`	Tên hình ảnh, không chứa tên thư mục
`sentence_id`	**Số thứ tự câu Nôm trong trang Nôm** (không phải thứ tự cột trong trang Nôm), với số thứ tự đánh từ 1. **Bắt buộc theo định dạng `<img_id bỏ đuôi .jpg>.<số thứ tự câu>`**, ví dụ `Lorem ipsum.024.1`
`ch_txt`	Văn bản Hán Nôm
`vi_txt`	Văn bản Quốc ngữ
`text_diff`	Mảng JSON ghi các vị trí khác nhau giữa văn bản Hán Nôm và Quốc ngữ (xem **Cột `text_diff`**). Giá trị `[]` nếu đã so sánh và không có chữ nào khác nhau; giá trị `null` (ghi đúng bốn chữ `null`, không để ô trống) nếu không so sánh (không phải dịch âm 1-1).

- Ví dụ:

img_id	sentence_id	ch_txt	vi_txt	text_diff
Lorem ipsum.024.jpg	Lorem ipsum.024.1	経申母福。[1]	Kinh Thân Mẫu Phúc.	`[]`
Lorem ipsum.024.jpg	Lorem ipsum.024.2	経福実糝緡。[2]	Kinh Phúc Thật Tám Mối.	`[]`
Lorem ipsum.025.jpg	Lorem ipsum.025.1	経告命。[3]	Kinh Cáo Mình.	`[]`
Lorem ipsum.026_1.jpg	Lorem ipsum.026_1.1	経天主。共経亞螞。[4]	Kinh Thiên Chúa. cùng kinh A-ve.	`[]`
Lorem ipsum.027.jpg	Lorem ipsum.027.1	翁聖丕離批[5]	Ông Thánh Philiphê	`[{"nom_pos":[[2,5]],"nom_sub_text":"丕離批","vi_pos":[[10,18]],"vi_sub_text":"Philiphê","type":"warn"}]`
Lorem ipsum.027.jpg	Lorem ipsum.027.2	経申母福。[6]	Kinh Thân Cha Phúc.	`[{"nom_pos":[[2,3]],"nom_sub_text":"母","vi_pos":[[10,13]],"vi_sub_text":"Cha","type":"error"}]`

- Hai dòng cuối minh hoạ `text_diff` khác rỗng: dòng `027.1` là trường hợp `warn` (tên riêng 丕離批 3 chữ và `Philiphê` không khớp số chữ nhưng đúng nghĩa), dòng `027.2` là trường hợp `error` (母 và `Cha` khác nghĩa). Xem **Cột `text_diff`**.
- File `.csv` phải mở được bình thường bằng Excel hoặc Google Sheets (không lỗi font, không lệch cột), ví dụ lưu UTF-8 có BOM.

[1] tr. 20r, Borg. Tonch. 18: Sách kinh Thầy cả Bỉnh, https://www.digitizingvietnam.com/vi/our-collections/the-han-nom-catholic-prayer-philipphe-binh/borg-tonch-18

[2] tr. 19v, Borg. Tonch. 18: Sách kinh Thầy cả Bỉnh, https://www.digitizingvietnam.com/vi/our-collections/the-han-nom-catholic-prayer-philipphe-binh/borg-tonch-18

[3] tr. 20v, Borg. Tonch. 18: Sách kinh Thầy cả Bỉnh, https://www.digitizingvietnam.com/vi/our-collections/the-han-nom-catholic-prayer-philipphe-binh/borg-tonch-18

[4] tr. 17v, Borg. Tonch. 18: Sách kinh Thầy cả Bỉnh, https://www.digitizingvietnam.com/vi/our-collections/the-han-nom-catholic-prayer-philipphe-binh/borg-tonch-18

[5] tr. 15, Sách Truyện Các Thánh (Tháng 5)

[6] tr. 20r, Borg. Tonch. 18: Sách kinh Thầy cả Bỉnh, https://www.digitizingvietnam.com/vi/our-collections/the-han-nom-catholic-prayer-philipphe-binh/borg-tonch-18

- Cấu trúc file `<Tên sách>.xlsx`:
  - Cấu trúc giống như Cấu trúc file `<Tên sách>.csv`.
  - Tô màu chữ Nôm và chữ Quốc ngữ để thể hiện tình trạng dóng hàng:
    - Chỉ tô màu khi dóng hàng giữa chữ Nôm và chữ Quốc ngữ (bản dịch âm), nghĩa là bản dịch 1-1. Các trường hợp còn lại không tô màu và cột `text_diff` ghi `null`.
    - Màu đen (**bắt buộc**): Chữ Nôm và chữ Quốc ngữ giống nhau về nghĩa (có thể dùng từ điển để kiểm tra).
    - Màu đỏ (**bắt buộc**):
      - Chữ Nôm và chữ Quốc ngữ khác nhau về nghĩa (có thể dùng từ điển để kiểm tra).
      - Chữ Nôm không tìm thấy trong từ điển cũng được tính là sai: tô màu đỏ (cho cả chữ Nôm và chữ Quốc ngữ tương ứng). Chỉ tô đỏ sau khi đã tra tất cả các từ điển: nếu chữ Nôm không có trong dữ liệu từ điển được bàn giao thì phải tra trực tiếp trên các website từ điển trực tuyến (Xem **Nguồn từ điển**).
      - Các chữ tô màu đỏ phải được thêm vào cột `text_diff`, dạng `error` (Xem **Cột `text_diff`**).
    - Màu vàng (không bắt buộc, nếu có), chỉ được dùng trong các trường hợp sau:
      - Chữ Nôm và chữ Quốc ngữ không khớp số ký tự, nhưng đúng về nghĩa, thường là các trường hợp đặc biệt tên riêng hoặc năm.
      - Bản dịch Nôm được dự đoán từ bản dịch âm Quốc ngữ, do chữ Nôm bị lem, bị nhoè không nhìn rõ (Xem **Quy định chung về dữ liệu văn bản**).
      - Bản dịch Nôm được dự đoán từ bản dịch âm Quốc ngữ, do bản scan bị mất trang Nôm. **Chỉ thực hiện khi có yêu cầu cụ thể** (khi đó hình ảnh Quốc ngữ được đưa lại vào thư mục `vi`, xem **Quy định chung về file hình ảnh**). Hạn chế dịch ngược từ âm Quốc ngữ sang Nôm mà nên tìm bản Nôm gốc hoặc yêu cầu bản scan lại để bổ sung.
      - Bản dịch âm Quốc ngữ được dự đoán từ văn bản Nôm, có thể do bản scan bị mất trang Quốc ngữ, có thể dựa vào từ điển hoặc các bản dịch đã có để tổng hợp bản dịch âm (có thể áp dụng phương pháp dịch máy dựa trên ví dụ - EBMT) (Xem **Quy định chung về file hình ảnh**).
      - Các chữ tô màu vàng phải được thêm vào cột `text_diff`, dạng `warn` (Xem **Cột `text_diff`**).
    - Ví dụ:
      - Chữ 一 và `nhất` giống nghĩa nhau → tô màu đen cho cả hai chữ.
      - Chữ 一 và `nhị` khác nghĩa nhau → tô màu đỏ cho cả hai chữ.
      - Tên riêng bản Nôm 丕離批 (Philiphê) (3 chữ) và bản Quốc ngữ (hoặc có dấu gạch ngang) `Philiphê` (1 chữ) (thường là bản dịch cũ các âm sẽ được ghép lại với nhau).
      - Hoặc tên riêng dịch từng âm với bản Nôm 丕抾蘇山蘇[7] (5 chữ) và bản Quốc ngữ `Phi-ri-tô San-tô` (Spiritus Sancti — Thần Khí/Chúa Thánh Thần) (5 chữ).
      - Bản Nôm 沒𠄩甪㪷點迸没[8] (`một nghìn năm trăm bảy mươi mốt`) (7 chữ) và bản Quốc ngữ `1571` (1 số) không khớp số chữ nhưng giống nhau về nghĩa → tô màu vàng cho cả hai cụm chữ.

[7] tr. 17r, Borg. Tonch. 18: Sách kinh Thầy cả Bỉnh, https://www.digitizingvietnam.com/vi/our-collections/the-han-nom-catholic-prayer-philipphe-binh/borg-tonch-18

[8] tr. 72, Sách Truyện Các Thánh (Tháng 5)

Cột `text_diff`

- Giá trị của cột là **một chuỗi JSON hợp lệ** (mã hoá UTF-8): một mảng, mỗi phần tử mô tả một cặp vị trí khác nhau giữa chữ Nôm và chữ Quốc ngữ. Nếu mọi chữ đều giống nhau (tô màu đen) thì ghi `[]`.
- Cột này chỉ có nghĩa với dóng hàng dịch âm (bản dịch 1-1), cùng điều kiện với việc tô màu trong file `.xlsx`. Với các hàng còn lại (dịch nghĩa, kiểu `1--n`, `n--1`, `n--m`) ghi `null`, **không** ghi `[]`, vì `[]` nghĩa là đã so sánh và giống nhau hoàn toàn.
- Mỗi phần tử có các trường sau:

Trường	Kiểu	Chú thích
`nom_pos`	mảng các khoảng	Vị trí các ký tự Nôm trong cột `ch_txt`, mỗi khoảng là `[start, end]`.
`nom_sub_text`	chuỗi	Văn bản Nôm tại `nom_pos`: nối các đoạn con theo thứ tự các khoảng, không thêm ký tự ngăn cách.
`vi_pos`	mảng các khoảng	Vị trí các ký tự Quốc ngữ trong cột `vi_txt`, quy ước như `nom_pos`.
`vi_sub_text`	chuỗi	Văn bản Quốc ngữ tại `vi_pos`, quy ước như `nom_sub_text`.
`type`	chuỗi	Chỉ nhận một trong hai giá trị: `"warn"` (tô vàng) hoặc `"error"` (tô đỏ).

Quy ước về vị trí (`pos`)

- Mỗi khoảng `[start, end]` là **khoảng nửa mở** [start, end): `start` được tính, `end` không được tính. Chỉ số **đánh từ 0**, `start` < `end`.
- Chỉ số tính theo **ký tự Unicode (code point)** của đúng chuỗi trong ô tương ứng, **không** tính theo byte hay UTF-16. Chữ Nôm ở mặt phẳng mở rộng (Ext B trở đi) vẫn chỉ là 1 ký tự.
- Cả văn bản Nôm và Quốc ngữ phải ở dạng chuẩn hoá **Unicode NFC** (và lưu đúng chuỗi đó trong ô) trước khi tính chỉ số (chữ có dấu là 1 ký tự, không tách dấu).
- `[MASK]` chiếm đúng 6 ký tự trong chuỗi, không nằm trong bất kỳ `pos` nào, tô màu đen và không tính vào mẫu số của công thức **Đánh giá dữ liệu**.
- Một trường `pos` có thể gồm nhiều khoảng, sắp xếp tăng dần và không chồng nhau, ví dụ `[[0,1],[2,4]]`.
- Mỗi khoảng là một đoạn liền mạch của chuỗi, **có thể chứa khoảng trắng, dấu gạch nối hoặc dấu câu ở bên trong** (ví dụ cả cụm `Kinh Thân Mẫu Phúc`, hay `A-ve`), nhưng **ký tự đầu và ký tự cuối của khoảng phải là chữ**, không phải khoảng trắng hoặc dấu câu. Một câu được dự đoán toàn bộ (tô vàng) chỉ cần ghi một khoảng duy nhất.
- Dùng JSON chuẩn: các phần tử cách nhau bằng dấu phẩy (`,`), **không** dùng dấu chấm phẩy (`;`), khoá và chuỗi đặt trong dấu nháy kép.
- Trong file `.csv`, chuỗi JSON phải được bao bằng dấu nháy kép và mỗi dấu nháy kép bên trong được nhân đôi (`""`) theo chuẩn CSV, dùng thư viện như `csv` hoặc `pandas` thay vì tự ghép chuỗi.
- Nếu một vế không có chữ tương ứng (ví dụ Nôm thừa chữ so với Quốc ngữ), vế đó ghi `pos` là `[]` và `text` là `""`. Hai vế không được cùng rỗng.

Quan hệ với màu trong file `.xlsx`

- `text_diff` và màu chữ trong `.xlsx` phải **khớp hoàn toàn**, mỗi ký tự thuộc đúng một trạng thái:
  - Ký tự nằm trong `nom_pos` hoặc `vi_pos` của phần tử `"error"` → tô **đỏ**.
  - Ký tự nằm trong `nom_pos` hoặc `vi_pos` của phần tử `"warn"` → tô **vàng**.
  - Ký tự không nằm trong bất kỳ `pos` nào → màu **đen**.
- **Một ký tự không thể vừa `warn` vừa `error`**: trong cùng một ô, các khoảng `pos` của toàn bộ phần tử (cả hai loại `type`) không được chồng nhau.
- Khoảng trắng, dấu gạch nối và dấu câu nằm bên trong một khoảng được tô cùng màu với khoảng đó; khoảng trắng và dấu câu nằm ngoài mọi khoảng (kể cả dấu câu ở đầu hoặc cuối) không tô màu (màu đen).
- Màu đen không cần ghi vào `text_diff`. Quy tắc tô màu đỏ/vàng/đen xem phần mô tả màu ở trên.
- Khi `text_diff` (file `.csv`) và màu chữ (file `.xlsx`) không khớp nhau, **`text_diff` trong file `.csv` là căn cứ chính thức** (để đánh giá và kiểm tra); file `.xlsx` chủ yếu để hiển thị.
- Số chữ không tương đồng dùng trong công thức **Đánh giá dữ liệu** được tính trên từng phần tử `"error"`:
  - Lấy giá trị lớn hơn giữa số chữ Nôm (số chữ Hán/Nôm trong các khoảng của `nom_pos`, **không tính dấu câu và khoảng trắng**) và số âm tiết Quốc ngữ (số từ chứa ít nhất một chữ cái, tách bởi khoảng trắng hoặc dấu gạch nối, trong từng khoảng của `vi_pos`)
  - Cộng các phần tử lại.
  - Ví dụ:
    - Nôm: 母 (mẫu) tính 1 chữ; khoảng Nôm 経天主 。共経亞螞 。(Kinh Thiên Chúa. cùng kinh A-ve.) tính 7 chữ (dấu 。không tính).
    - Quốc ngữ: `Kinh Mẹ Phúc` tính 3 chữ; `A-ve` tính 2 chữ.

Ví dụ

Ô `ch_txt`: 母聖丕離批 。, ô `vi_txt`: `cha Thánh Philiphê.` Giá trị `text_diff` tương ứng (trong file thật nằm trên **một dòng**, chữ Nôm là ký tự thật):

```
[{"nom_pos":[[2,5]],"nom_sub_text":"<丕離批>","vi_pos":[[10,18],"vi_sub_text":"Philiphê","type":"
    warn"},
 {"nom_pos":[[0,1]],"nom_sub_text":"< 母>","vi_pos":[[0,3]],"vi_sub_text":"cha","type":"error"}]
```

- Phần tử `warn`: 丕離批 (3 chữ) và `Philiphê` (1 chữ) không khớp số chữ nhưng đúng nghĩa (tên riêng) → tô vàng.
- Phần tử `error`: 母 và `cha` khác nhau → tô đỏ.
- 聖/`Thánh` giống nhau nên không có trong `text_diff` (màu đen).

Ví dụ câu 経申母福 。/ `Kinh Thân Mẫu Phúc.` được dự đoán toàn bộ (tô vàng): chỉ cần một khoảng cho mỗi vế, bao gồm cả khoảng trắng bên trong và không gồm dấu chấm cuối câu:

```
[{"nom_pos":[[0,4]],"nom_sub_text":"<経申母福>","vi_pos":[[0,18]],"vi_sub_text":"Kinh Thân Mẫu
    Phúc","type":"warn"}]
```

> **Lưu ý**
>
> Nên kiểm tra tự động trước khi nộp: với mỗi phần tử, `nom_sub_text`/`vi_sub_text` phải bằng đúng chuỗi cắt từ ô theo `pos`; các khoảng không chồng nhau; màu trong `.xlsx` khớp với `text_diff`.

Các kiểu dóng hàng được chấp nhận

- `1--1`: một câu/đoạn Nôm tương ứng một câu/đoạn Việt.
- `1--n`: một đơn vị Nôm tương ứng nhiều câu Việt; gộp các câu Việt liên quan vào cùng một ô.
- `n--1`: nhiều câu Nôm tương ứng một câu Việt; gộp các câu Hán liên quan vào cùng một ô.
- `n--m`: chỉ dùng khi bản dịch tái cấu trúc mạnh và không thể tách nhỏ hơn mà vẫn giữ đúng nghĩa.
- Với các kiểu `n--1` và `n--m`, `sentence_id` của hàng là `sentence_id` của câu Nôm đầu tiên được gộp.

> **Lưu ý**
>
> Ưu tiên đơn vị nhỏ nhất có ý nghĩa đầy đủ. Không chia cơ học theo dấu câu nếu việc chia làm mất quan hệ dịch.

Tiêu chí một cặp dóng hàng đúng

- Một cặp được xem là đúng khi:
  1. Hai vế nói về cùng nội dung.
  2. Không bỏ mất ý quan trọng.
  3. Không thêm nội dung thuộc câu/đoạn khác.
  4. Tên riêng, chức danh, địa danh cơ bản tương ứng.
  5. Thời gian, niên hiệu và con số tương ứng.
  6. Ranh giới câu/đoạn hợp lý.
  7. Không phải dòng tiêu đề, số trang hoặc OCR rác ghép nhầm.
- Đối với tên nhân vật hoặc tên riêng, có thể dùng bản dịch âm (nếu có) để xác định các tên đặc biệt để xử lý riêng hoặc xử lý thủ công.
- **Nếu là dịch âm thì số chữ Quốc ngữ thông thường bằng số chữ Hán Nôm**. Một số trường hợp đặc biệt (Xem **Quy định chung về việc dóng hàng**).
- Không thực hiện dóng hàng với các chữ được đánh `[MASK]` (Xem **Quy định chung về dữ liệu văn bản**).
- Nếu không phải là dịch âm thì bản dịch không cần sát từng chữ; đánh giá dựa trên quan hệ dịch và phạm vi nội dung. Cột `text_diff` của hàng đó ghi `null`.

Quy định chung về file báo cáo

- Tên file báo cáo dựa trên tên file zip theo các thầy đã phổ biến.
- Thông tin của từng thành viên: họ tên, mssv, email sinh viên.
- **Cấu trúc báo cáo dựa theo hướng dẫn của các thầy (nếu có)**. Có thể viết bằng Word, Google Docs, LaTeX,...**miễn là file PDF là được**.
- Mô tả các việc nhóm đã làm, như thiết lập mô hình, cào dữ liệu,...
- Tỷ lệ chữ tô màu vàng trên tổng số chữ Nôm của sách và lý do (Xem **Đánh giá dữ liệu**).
- Tỷ lệ số hàng `null` (không so sánh) trên tổng số hàng của sách (Xem **Đánh giá dữ liệu**).
- Phần trích dẫn (nếu có).

> **Lưu ý**
>
> Phần phụ lục phải đính kèm các hình ảnh như sau:
> - Ảnh chụp mẫu một trang Hán Nôm mở được bằng công cụ PPOCRLabel (kiểm tra xem có đúng format, bounding box có đúng vị trí hay không).
> - Ảnh chụp mẫu một trang Quốc ngữ mở được bằng công cụ PPOCRLabel (kiểm tra xem có đúng format, bounding box có đúng vị trí hay không).
> - Ảnh chụp mẫu trang tính (.xlsx) cho thấy file mở được và không bị lỗi font.
> - Ảnh chụp mẫu trang tính (.csv) cho thấy file mở được bình thường bằng Excel hoặc Google Sheets và không bị lệch cột.

Quy định chung về mã nguồn

- Không giới hạn ngôn ngữ lập trình như đã đề cập ở phần **Quy định chung**, nhưng **ưu tiên Python**.
- File **README.md**:
  - Mô tả chi tiết dự án.
  - Mô tả tổng quan cách chạy dự án (cách cài thư viện, chạy lệnh,...).
- Các thư viện cài đặt (dependencies) **PHẢI** được cố định (pinned).
- Nếu chạy trên Google Colab thì các thư viện cài đặt (dependencies) cũng phải được cố định (pinned), mô tả môi trường (runtime, cấu hình secrets nếu có).
- File **USER_GUIDE.md**:
  - **Mô tả chi tiết cách chạy quy trình (pipeline) từ đầu đến cuối** như trên một máy tính mới, **với dữ liệu mà nhóm đã nộp**.
  - Đối với các công cụ/mô hình có tính phí cũng cần được chú thích đầy đủ về mô hình, prompt đã sử dụng, cách cài đặt (token,...).
  - Chú thích rõ môi trường mà dự án đã chạy, như phiên bản Python, OS (**ưu tiên Ubuntu**), RAM, cấu hình đồ hoạ,...

Đánh giá dữ liệu

- Dữ liệu được đánh giá dựa trên phần trăm độ tương đồng của từ chữ Nôm và chữ Quốc ngữ:

$$\textbf{độ tương đồng (\%)} = \left(1 - \frac{\text{tổng số chữ không tương đồng (chữ đỏ)}}{\text{tổng số chữ Nôm tính điểm}}\right) \times 100$$

- Tổng số chữ Nôm tính điểm (mẫu số) chỉ tính các chữ Nôm trong các hàng có `text_diff` khác `null`, không tính chữ Quốc ngữ, dấu câu, `[MASK]` và **các chữ tô màu vàng**. Ví dụ sách có 100 chữ Nôm, trong đó 4 chữ tô vàng, và 100 chữ Quốc ngữ, thì mẫu số là 96.
- Cách tính số chữ không tương đồng (tử số) xem **Quan hệ với màu trong file `.xlsx`**. Điểm được tính theo `text_diff` trong file `.csv`.
- Chữ tô màu vàng chỉ được dùng trong các trường hợp đã liệt kê ở **Cấu trúc file dóng hàng (align)**. Nhóm phải báo cáo tỷ lệ chữ tô vàng trên tổng số chữ Nôm của sách.
- Sách không phải dịch âm (toàn bộ `text_diff` là `null`) không áp dụng công thức này; tiêu chí đánh giá sẽ được thay đổi để phù hợp với tính chất của sách.
- Điểm chỉ tính trên chữ Nôm của các hàng dịch âm (`text_diff` khác `null`). Báo cáo phải nêu tỷ lệ số hàng `null` trên tổng số hàng của sách.
- Về độ chính xác yêu cầu cố gắng cao nhất có thể (best effort), không yêu cầu phải chính xác tuyệt đối.
- **Yêu cầu độ tương đồng của sách phải đạt tối thiểu là 95% ($\geq$95%)**. Đây chỉ là mức tiêu chuẩn, tiêu chí đánh giá có thể thay đổi để phù hợp với tính chất và tình trạng của sách được giao.

Thông tin tham khảo

> **Lưu ý**
>
> Các thông tin dưới đây **chỉ mang tính chất tham khảo**, không bắt buộc các nhóm phải sử dụng.

Mô hình OCR chữ Nôm

Tên mô hình / Công cụ	Liên kết tài nguyên
Công cụ chuyển tự và OCR Hán Nôm (Ưu tiên)	Website
PP-OCRv5 (Baidu)	GitHub | ArXiv | Demo
HunyuanOCR (Tencent)	Huggingface
PaddleOCR-VL (Baidu)	ArXiv | Weights | GitHub
GLM-OCR (Z.ai)	Huggingface
HanDoc-OrderOCR	GitHub
Qwen2.5-VL-7B-Instruct (Alibaba)	Huggingface
Qianfan-OCR (Baidu)	Huggingface
Qwen3.5-9B (Alibaba)	Huggingface

> **Lưu ý**
>
> Vì sao có thể dùng tạm mô hình OCR chữ Hán cho dữ liệu Hán Nôm:
> - Chữ Nôm được người Việt tạo ra dựa trên chữ Hán (mượn nguyên chữ Hán hoặc ghép từ các thành phần chữ Hán), và văn bản Hán Nôm cũng chứa nhiều chữ Hán thuần, nên phần lớn chữ, nét và bộ thủ đã nằm trong tập ký tự mà mô hình OCR chữ Hán học được.
> - Hạn chế: chữ Nôm tự tạo mà mô hình chưa từng gặp dễ bị nhận sai hoặc bỏ sót, và các mô hình này chưa được tinh chỉnh cho bản in hoặc bản viết tay cổ, nên kết quả cần được đối chiếu với từ điển và sửa tay.

Mô hình OCR chữ Quốc ngữ

Tên mô hình / Công cụ	Liên kết tài nguyên
MonkeyOCRv2	GitHub | Paper
HunyuanOCR (Tencent)	Huggingface
PaddleOCR-VL (Baidu)	ArXiv | Weights | GitHub
dots.ocr (rednote-hilab)	Huggingface
Qwen2.5-VL-7B-Instruct (Alibaba)	Huggingface
Vintern-1B-v2 (5CD-AI)	Huggingface
Qianfan-OCR (Baidu)	Huggingface
Qwen3.5-9B (Alibaba)	Huggingface

Mô hình dóng hàng Nôm – Quốc ngữ

Công trình / Phương pháp & Tác giả	Liên kết tài nguyên
Ancient-Modern Chinese Translation Liu, Lv, Yang, Qu (ACM TALLIP)	ArXiv | DOI
Transliterating Nôm Scripts into Vietnamese Dinh, Nguyen, Nguyen (IJACSA, vol. 12, no. 2, 2021)	Paper PDF
SentAlign Steingrímsson, Loftsson, Way (EMNLP 2023 Demo)	ACL Anthology | GitHub
Bertalign Liu & Zhu (Digital Scholarship in the Humanities, 2022)	DOI | PyPI
Vecalign Thompson & Koehn (EMNLP-IJCNLP 2019)	ACL Anthology

Mô hình kiểm tra chính tả (Spellcheck)

Phân loại	Tên mô hình / Công cụ	Mô tả chi tiết	Liên kết tài nguyên
Hán / Hán Nôm	**SCOPE**	Kiểm tra chính tả tiếng Trung	ArXiv | GitHub | Checkpoint
Hán / Hán Nôm	**ReaLiSe**	Mô hình sửa lỗi chính tả tiếng Trung	ACL | GitHub | Checkpoint
Quốc ngữ	**BARTpho**	Mô hình ngôn ngữ tiếng Việt (syllable)	Huggingface
Quốc ngữ	**ViSoBERT**	Mô hình BERT tiếng Việt	Huggingface

Nguồn từ điển

Tên từ điển	Ngôn ngữ / Phạm vi hỗ trợ	Liên kết tài nguyên
Nôm Na Việt	Chữ Hán Nôm – Quốc ngữ (âm đọc)	Website
Unihan (Unicode Consortium)	Chữ Hán/CJK, âm Hán-Việt, Quan thoại, Quảng Đông, Nhật, Hàn, nghĩa Anh	Mô tả | Dữ liệu Unihan.zip
Bảng chữ Hán Nôm chuẩn (Hannom-RCV)	Chữ Hán Nôm – Quốc ngữ (âm đọc)	Website

Tên từ điển	Ngôn ngữ / Phạm vi hỗ trợ	Liên kết tài nguyên
Bảng Tra Chữ Nôm (Quỹ BT Di sản Nôm)	Chữ Nôm – Quốc ngữ	Website
Digitizing Vietnam	Bộ từ điển Hán Nôm	Website
HVDIC	Hán-Việt và Nôm – tiếng Việt	Website
Đại Nam Quấc âm tự vị (1895)	Quốc ngữ – Quốc ngữ, có kèm Hán Nôm (Wikisource)	Wikisource
Wiktionary tiếng Việt	Việt – Việt, có bảng Hán-Việt và Nôm	Website
Wiktionary tiếng Anh (Kaikki.org)	Đa ngôn ngữ (Trung, Việt, Nhật, Hàn…), giải nghĩa tiếng Anh	Website
CC-CEDICT	Trung – Anh	Website
CC-Canto	Âm Quảng Đông (Jyutping) cho CC-CEDICT	Download
Make Me a Hanzi	Chữ Hán, nghĩa tiếng Anh, cấu tạo, từ nguyên, bộ thủ	GitHub
cjkvi-ids & cjkvi-variants	Chữ Hán/CJK, cấu trúc ký tự và quan hệ dị thể	cjkvi-ids | cjkvi-variants
MOE Revised Mandarin Dictionary	Quan thoại (Đài Loan) – Quan thoại	GitHub
ERDRG (JMdict, KANJIDIC2)	Nhật – Anh, kanji	Website
Kengdic	Hàn – Anh	GitHub
vdict	Anh – Việt, Việt – Anh, Việt – Việt	Website
vtudien	Anh – Việt, Trung – Việt, Việt – Trung, Việt – Việt	Website

Font chữ

Tên font	Mô tả & Hướng dẫn	Liên kết tài nguyên
HAN NOM A, HAN NOM B (VietUnicode)	Font chữ Hán Nôm tiêu chuẩn	Mô tả | Tải về
Nom Na Tong Light (Quỹ Bảo tồn Nôm)	Font chữ Nôm chuyên dụng	Hướng dẫn | Nom Foundation
Han-Nom Gothic, Han-Nom Ming, Han-Nom Kai	Hannom-RCV	Website
HanaMin A, HanaMin B	Font chữ CJK/Hán Nôm rộng	Hướng dẫn
MingLiU, MingLiU-ExtB	Font hệ thống hỗ trợ ExtB	Website

Công cụ hỗ trợ

Tên công cụ	Mô tả chức năng chính	Liên kết tài nguyên
PPOCRLabel	Hỗ trợ đánh dấu bounding box cho OCR	GitHub
pdfarranger	Hỗ trợ sắp xếp/chỉnh sửa file PDF (Linux)	GitHub
pdfslice-py	Hỗ trợ chia trang file PDF	GitHub

Phụ lục

Chú thích về phân loại sách

Code (Mã)	Layout & Script Description (Mô tả bố cục & chữ viết)
T1	Quốc ngữ nằm ở phần đầu, Nôm ở phần cuối. Thứ tự đọc trang Quốc ngữ từ trái sang phải, thứ tự đọc trang Hán Nôm từ phải sang trái. Ví dụ: trang 1 QN là bản dịch của trang 10 HN, trang 2 QN là bản dịch của trang 9 HN. Cũng có trường hợp 1 trang QN là bản dịch của 2 trang HN.
T1w	T1 nhưng viết tay Nôm (w là writing)
T2	Xen kẽ (Ví dụ: Phải: Nôm, Trái: Quốc ngữ)
T2w	T2 nhưng viết tay Nôm (w là writing)
T2b	Quốc ngữ và Nôm chung trang
T2bw	T2b nhưng viết tay Nôm (w là writing)
Tref	Tham khảo
Tx	Loại khác
Tqn	Chỉ có Quốc ngữ
Tnom	Chỉ có Nôm
Tnomw	Chỉ có viết tay Nôm (w là writing)
Chưa phân loại	Chưa phân loại

Loại dữ liệu văn bản thuần

Đối với loại tài liệu văn bản thuần chỉ có văn bản Hán Nôm và văn bản Quốc ngữ, không có hình ảnh sẽ có vài thay đổi về cấu trúc dữ liệu nộp và cấu trúc file dóng hàng.

Cấu trúc dữ liệu nộp - Loại dữ liệu văn bản thuần

```
<MSSV1_MSSV2_MSSV3_MSSV4>.zip/
|-- <Tên sách>/
|   |-- <Tên sách>.xlsx (dữ liệu đã dóng hàng)
|   `-- <Tên sách>.csv (dữ liệu đã dóng hàng)
|-- <MSSV1_MSSV2_MSSV3_MSSV4>_report.pdf (dựa theo tên file zip)
|-- source.zip
`-- extras.zip (dữ liệu thêm,...)
```

Quy định về việc đánh bounding box - Loại dữ liệu văn bản thuần

Không có hình ảnh nên không đánh bounding box.

Cấu trúc file dóng hàng (align) - Loại dữ liệu văn bản thuần

- Cấu trúc file `<Tên sách>.csv`:

Tên cột	Chú thích
`sentence_id`	**Số thứ tự câu Nôm**, với số thứ tự đánh từ 1
`ch_txt`	Văn bản Hán Nôm
`vi_txt`	Văn bản Quốc ngữ

- Ví dụ:

sentence_id	ch_txt	vi_txt
1	経申母福。	Kinh Thân Mẫu Phúc.
2	経福実糝緡。	Kinh Phúc Thật Tám Mối.
3	経告命。	Kinh Cáo Mình.

- Cấu trúc file `<Tên sách>.xlsx`:
  - Cấu trúc giống như Cấu trúc file `<Tên sách>.csv`.

Loại dữ liệu hình ảnh chưa được ghép thành file PDF

Đối với loại dữ liệu hình ảnh chưa được ghép thành file PDF, được chia làm các loại chính:

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn. Có thể dịch theo toàn trang, theo từng cột hoặc theo từng chữ.
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**: thường là tài liệu dịch nghĩa của tài liệu Hán Nôm, ít phổ biến hơn, thường là sách cũ.

Quy định về việc ghép hình ảnh - Loại dữ liệu hình ảnh chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Sắp xếp hình ảnh vào thư mục `ch` như đã quy định.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `Tnom_<tên>.pdf` hoặc `Tnomw_<tên>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Sắp xếp hình ảnh vào thư mục `ch` như đã quy định.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `Tnom_<tên>.pdf` hoặc `Tnomw_<tên>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Sắp xếp hình ảnh vào thư mục `ch` và `vi` như đã quy định.
  - Sắp xếp bản dịch Quốc ngữ ở phần đầu, hình ảnh chụp Hán Nôm ở phần sau tài liệu.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `T1_<tên>.pdf` hoặc `T1w_<tên>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).

> **Lưu ý**
>
> Đối với hình ảnh được thu thập trên mạng, luôn đảm bảo hình ảnh thu thập có độ phân giải cao nhất.

Cấu trúc dữ liệu nộp - Loại dữ liệu hình ảnh chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Cấu trúc dữ liệu nộp không có thư mục `vi`.
  - Xem **Quy định chung về dữ liệu nộp**.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Cấu trúc dữ liệu nộp không có thư mục `vi`.
  - Xem **Quy định chung về dữ liệu nộp**.
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Cấu trúc dữ liệu nộp có đủ thư mục `ch` và `vi`.
  - Xem **Quy định chung về dữ liệu nộp**.

Quy định về việc đánh bounding box - Loại dữ liệu hình ảnh chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Chỉ đánh bounding box cho hình ảnh trong thư mục `ch`.
  - Xem **Quy định chung về việc đánh bounding box**.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Chỉ đánh bounding box cho hình ảnh trong thư mục `ch`.
  - Xem **Quy định chung về việc đánh bounding box**.

  > **Lưu ý**
  >
  > Văn bản Hán Nôm phải được tách ra để khớp với dữ liệu bounding box.

- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Đánh bounding box cho hình ảnh trong thư mục `ch` và `vi`.
  - Xem **Quy định chung về việc đánh bounding box**.

Cấu trúc file dóng hàng (align) - Loại dữ liệu chưa được ghép thành file PDF

- **Ảnh chụp Hán Nôm và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Quy định chung về việc dóng hàng**.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Quy định chung về việc dóng hàng**.
- **Ảnh chụp Hán Nôm và Ảnh chụp bản dịch Quốc ngữ**:
  - Xem **Quy định chung về việc dóng hàng**.

Loại tài liệu đánh máy (file PDF)

Đối với loại tài liệu đánh máy (file PDF), được chia làm các loại chính:

- **Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn. Chữ Nôm được đánh ngang.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**: thường là tài liệu được dịch trên mạng (chủ yếu là dịch âm), phổ biến hơn. Có thể dịch theo toàn trang, theo từng cột hoặc theo từng chữ. Chữ Nôm được đánh ngang.

Quy định về việc ghép hình ảnh - Loại tài liệu đánh máy (file PDF)

- **Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Không có hình ảnh chụp Hán Nôm nên không xử lý.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Nếu ảnh chụp Hán Nôm nằm chung trang với văn bản Hán Nôm hoặc bản dịch Quốc ngữ (thường là T2b):
    - Cắt hình ảnh thành từng file riêng.
    - Thêm `[_<Số thứ tự hình ảnh>]` cho tên file (Xem **Quy định chung về file hình ảnh**).
  - Sắp xếp hình ảnh vào thư mục `ch` như đã quy định.
  - Các hình ảnh được ghép thành file PDF và đặt tên theo cú pháp `Tnom_<tên>.pdf` hoặc `Tnomw_<tên>.pdf` (cho loại chữ Hán Nôm viết tay) (Xem **Phụ lục - Chú thích về phân loại sách**).

Cấu trúc dữ liệu nộp - Loại tài liệu đánh máy (file PDF)

- **Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Trích xuất dữ liệu văn bản trực tiếp từ file PDF.
  - Xem **Phụ lục - Loại dữ liệu văn bản thuần**.
- **Ảnh chụp Hán Nôm, Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Cấu trúc dữ liệu nộp không có thư mục `vi`.
  - Trích xuất dữ liệu văn bản trực tiếp từ file PDF.
  - Xem **Quy định chung về dữ liệu nộp**.

Quy định về việc đánh bounding box - Loại tài liệu đánh máy (file PDF)

- **Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Không có hình ảnh nên không đánh bounding box.
- **Ảnh chụp Hán Nôm, Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Chỉ đánh bounding box cho hình ảnh trong thư mục `ch`.
  - Xem **Quy định chung về việc đánh bounding box**.

> **Lưu ý**
>
> Văn bản Hán Nôm phải được tách ra để khớp với dữ liệu bounding box.

Cấu trúc file dóng hàng (align) - Loại tài liệu đánh máy (file PDF)

- **Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Phụ lục - Loại dữ liệu văn bản thuần**.
- **Ảnh chụp Hán Nôm, Bản dịch Hán Nôm văn bản thuần và Bản dịch Quốc ngữ văn bản thuần**:
  - Xem **Quy định chung về việc dóng hàng**.